

本周工作汇报

MAPPO 论文复现与训练结果分析

论文：

The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games (NeurIPS 2022)

一、本周工作内容

本周主要围绕论文《The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games》开展学习与复现工作。

首先，阅读论文并梳理了 MAPPO 的整体训练流程，重点理解了 CTDE (Centralized Training with Decentralized Execution, 集中训练、分散执行) 框架、PPO 更新机制以及 MPE (Multi-Agent Particle Environment) 中的 Simple Spread 协作任务。

随后，成功搭建论文作者开源代码环境，运行 MAPPO 在 MPE-Simple Spread 场景下的训练，并成功生成 TensorBoard 日志，完成了论文中部分实验的复现。

本周工作的重点不在于提出新的算法，而是验证论文所采用的 MAPPO 训练流程是否能够正常运行和收敛，并观察训练过程中各项指标的变化，为后续进一步修改算法、开展对比实验和分析多智能体协作行为奠定基础。

二、复现内容

本次复现环境如下：

- **算法：** MAPPO (Multi-Agent PPO)
- **环境：** MPE (Multi-Agent Particle Environment)
- **场景：** Simple Spread
- **Agent 数量：** 3

- **Landmark 数量：** 3
- **PPO Epoch：** 10
- **Episode Length：** 25
- **总训练步数：** 1,000,000

Simple Spread 可以理解为一个多智能体协作占点任务。环境中包含 3 个 Agent 和 3 个 Landmark，多个 Agent 需要在避免碰撞的同时，尽可能分散到不同的 Landmark 附近。每个 Agent 在每一个 Step 都会根据当前观测重新选择动作，多个 Agent 通过共享奖励逐渐形成隐式协作，而不需要进行显式消息通信。


训练完成后，成功生成 TensorBoard 日志，包括：

- Average Episode Rewards
- Value Loss
- Policy Loss
- Dist Entropy
- Ratio 等指标

整体来看，训练过程能够正常进行，各项指标变化趋势与论文中 MAPPO 的训练规律基本一致，说明项目环境、训练脚本和日志记录流程均已成功运行，也完成了论文实验的部分复现。

三、训练结果分析

(1) Average Episode Rewards



Average Episode Rewards 反映了智能体整体策略性能的变化，是评价强化学习训练效果最重要的指标之一。

从训练曲线可以看到：

- 训练初期平均奖励约为 **-200**；
- 随着训练进行，平均奖励逐渐提高至 **-180 左右**；
- 虽然训练过程中存在一定波动，但整体趋势持续上升。

由于 Simple Spread 的奖励主要由 **Agent 与 Landmark 的距离** 以及 **碰撞惩罚** 组成，因此奖励不断提高说明：

- Agent 已逐渐学会向 Landmark 靠近；
- 多个 Agent 开始形成一定的协作分工；
- Agent 同时靠近同一 Landmark 或相互碰撞的情况有所减少。

之所以会出现这一变化，是因为所有 Agent 共享团队奖励。当多个 Agent 扎堆到同一位置时，未被覆盖的 Landmark 会使团队总奖励降低；而当三个 Agent 分散到不同 Landmark 附近时，整体距离惩罚会减小。因此，共享奖励机制能够不断引导 Agent 从随机移动逐渐学习到分散占点的协作策略。

虽然最终奖励尚未完全收敛，但已经表现出明显的学习趋势，与论文中 MPE 环境训练曲线的整体变化规律一致。

(2) Value Loss



Value Loss 描述的是 Critic 网络预测状态价值时产生的误差。Critic 在训练阶段可以利用多个 Agent 的全局状态信息，预测从当前状态开始未来可能获得的累计回报。

实验结果表明：


- 训练初期 Value Loss 较大；
- 随后很快下降至较低水平；
- 后期保持在较稳定范围，仅存在一定幅度的小幅波动。

这一变化说明 Critic 网络在训练初期对状态价值的预测并不准确，但随着环境交互数据不断增加，Critic 能够逐渐学习当前状态与未来累计回报之间的关系。

Critic 预测得更加准确后，实际回报与预测价值之间计算得到的 Advantage 也会更加可靠，从而为 Actor 提供更准确的策略更新方向。如果 Critic 长期预测不准确，就可能错误地提高或降低某些动作的概率，因此 Value Loss 的下降和稳定对 PPO 的训练十分重要。

论文指出，Value Function 的稳定训练对于 MAPPO 性能具有重要影响，因此作者建议采用 **Value Normalization** 来减小不同阶段回报尺度变化带来的影响。当前实验中 Value Loss 能够较快下降并保持稳定，说明 Critic 网络整体训练过程正常。

(3) Dist Entropy



Dist Entropy 表示策略输出动作概率分布的随机程度，可以用来衡量 Agent 当前更偏向探索还是利用已有策略。

训练结果可以观察到：


- 初始阶段 Entropy 较高；
- 随着训练进行迅速下降；
- 后期保持在较低且相对稳定的水平。

这说明训练初期 Actor 网络参数尚未形成有效策略，不同动作的概率较为接近，因此 Agent 主要通过随机探索来尝试不同的移动方向。随着训练进行，一些能够提高团队奖励的动作模式被不断强化，Agent 对动作的选择逐渐形成明确偏好，策略由随机探索逐步转向稳定利用。

Entropy 下降的原因是 Actor 输出的动作概率分布逐渐集中。例如训练初期向上、向下、向左、向右的概率可能较为接近；训练后期，当 Agent 观察到 Landmark 和队友位置时，会更明确地选择某一方向，因此动作分布的随机性下降。

这一现象符合 PPO 的训练规律，也说明智能体已经逐渐从“随机移动”过渡到“根据局面进行有倾向性的决策”。不过 Entropy 也不宜过早下降到过低水平，否则可能导致探索不足并陷入局部最优，因此后续可以结合熵系数进一步分析探索程度对训练性能的影响。

(4) Policy Loss



Policy Loss 用于描述 Actor 网络在 PPO 更新过程中的变化情况，反映当前策略相对于旧策略的优化程度。

实验结果显示：

- Policy Loss 在训练初期变化较大；
- 随着训练进行，整体逐渐趋于稳定；
- 训练过程中没有出现持续放大、剧烈震荡或明显发散的现象。

训练初期 Policy Loss 波动较大，是因为 Actor 尚未形成稳定策略，新采集的数据会不断改变动作概率分布。随着训练进行，Agent 已经学会较有效的移动与协作方式，策略更新幅度逐渐减小，因此 Policy Loss 也趋于稳定。

PPO 使用 Clip 机制限制新旧策略之间的变化幅度，即使某一批数据带来了较大的 Advantage，也不会让 Actor 一次性改变过多。这种小步更新机制能够减少策略突然退化的风险，也是当前 Policy Loss 没有明显发散的重要原因。

结合 Average Episode Rewards 的上升以及 Value Loss 的稳定，可以说明 PPO 更新过程整体较为平稳，没有出现明显的策略崩溃现象，整个训练流程运行正常。

四、实验总结

本周成功完成了论文 MAPPO 在 MPE 环境中的部分复现工作。

实验结果表明：

- 项目能够正常完成训练；
- TensorBoard 能够成功记录并展示训练过程；
- Average Episode Rewards 呈持续提升趋势；
- Value Loss 在训练初期快速下降并逐渐稳定；
- Dist Entropy 从较高水平下降，说明策略由随机探索逐渐转向稳定决策；
- Policy Loss 未出现明显发散，表明 PPO 更新过程整体较为稳定。

整体来看，本次实验结果与论文中 MAPPO 在 MPE 环境中的训练表现基本一致，验证了代码实现及实验配置的正确性。通过本次复现，也进一步理解了 Actor、Critic、Advantage、PPO Clip 和 CTDE 等机制在多智能体训练中的具体作用。

目前的结果可以说明 MAPPO 已经在 Simple Spread 中学到一定的多智能体协作能力，但仅凭训练指标还不能完全说明最终策略已经达到最优。后续还需要结合不同随机种子、参数对比实验以及可视化运行结果，对模型的稳定性和实际协作行为进行进一步验证。

1. 对 PPO Epoch 和 Mini-batch 数量进行对比实验。

在其他参数保持不变的情况下，分别设置不同的 `ppo_epoch` 和 `num_mini_batch`，比较各组实验的 Average Episode Rewards、Value Loss 和 Dist Entropy 曲线，分析不同参数对收敛速度、最终奖励和训练稳定性的影响。该部分主要验证论文关于“训练轮数过多和 Mini-batch 划分过细可能降低 MAPPO 性能”的结论。

2. 使用多个随机种子验证实验结果的稳定性。

在基线配置和较优配置下分别使用 3 个随机种子重复训练，统计各组实验最终奖励的平均值和波动范围，避免仅根据单次实验得出结论。最终可以通过对比表格和多条奖励曲线展示不同配置的稳定性。

3. 对训练完成后的模型进行可视化运行。

加载基线模型和较优参数模型，观察三个 Agent 是否能够分散到不同 Landmark、是否存在重复占点和碰撞，并保存关键截图或录屏。该部分从行为层面验证训练曲线所反映的协作能力。

4. 在 Simple Spread 中加入一个轻量级改进实验。

在原有共享奖励基础上，增加一个简单的“重复占点惩罚”或“目标覆盖奖励”，例如当多个 Agent 同时靠近同一个 Landmark 时给予额外惩罚，鼓励 Agent 更快形成一对一的目标分配。随后将改进前后的 Average Episode Rewards、碰撞情况和重复占点现象进行对比，分析该奖励设计是否能够加快协作策略的形成。