

# MARVEL 论文多智能体强化学习算法分析报告

**论文标题:** MARVEL: Multi-Agent Reinforcement Learning for constrained field-of-View multi-robot Exploration in Large-scale environments

**发表会议:** ICRA 2025

**论文来源:** [ICRA-2025\_MARVEL\_Multi-Agent\_Reinforcement\_Learning\_for\_Constrained\_Field-of-View\_Multi-Robot\_Exploration\_in\_Large-Scale\_Environments]

## 一、论文概述

### 1.1 研究背景

传统多机器人探索方法普遍假设使用全向传感器（如 LiDAR），但对于无人机等小型机器人，由于载荷限制，只能使用轻量级、方向性传感器（如相机），这类传感器具有**受限视场（Constrained FoV）**。受限视场传感器为探索问题增加了额外复杂性：

- 视角规划:** 不仅需要规划位置，还需规划传感器朝向
- 稀疏奖励:** 传感器约束限制了前沿检测频率
- 信用分配:** 团队奖励需合理归因到单个智能体
- 时空短视:** 需平衡当前视角利用与长期探索

### 1.2 核心贡献

MARVEL 提出了一个基于图注意力网络的多智能体强化学习框架，主要贡献包括：

- 图注意力策略网络:** 利用图结构增强环境理解
- 前沿-朝向特征融合:** 智能融合前沿分布和方向信息
- 信息驱动动作剪枝:** 处理大规模动作空间
- 特权学习 Critic:** 增强信用分配能力
- CTDE 范式:** 集中训练、分散执行

## 二、环境组件详解

### 2.1 环境建模

**环境表示**（论文 Section III）：

- 环境建模为**有界占据栅格地图**  $E$ ，尺寸为  $x \times y$
- 分为自由区域  $E_f$  和占据区域  $E_o$ ，满足  $E_f \cup E_o = E$ ， $E_f \cap E_o = \emptyset$
- 每个智能体维护自己的**信念状态**  $B_i$ ，包含三个部分：

| 区域   | 符号    | 含义      |
|------|-------|---------|
| 自由区域 | $B_f$ | 已知可通行区域 |
| 占据区域 | $B_o$ | 已知障碍物区域 |

| 区域   | 符号    | 含义    |
|------|-------|-------|
| 未知区域 | $B_u$ | 未探索区域 |

探索率定义：

$$\rho = \frac{B_f}{E_f}$$

- 当  $\rho \geq 0.99$  时认为环境完全探索

2.2 传感器模型

受限视场传感器（论文 Section III）：

| 参数       | 默认值   | 说明        |
|----------|-------|-----------|
| 视场角（FoV） | 120°  | 传感器可见角度范围 |
| 感知范围     | 10m   | 传感器有效距离   |
| 速度       | 1 m/s | 智能体移动速度   |
| 最大偏航率    | 35°/s | 智能体转向速度   |

- 使用 **2D 扇形足迹**近似传感器视场
- 假设智能体之间**完美通信**，共享全局地图

2.3 图结构表示（关键创新）

碰撞-free 图构建（论文 Section IV.A）：

环境栅格地图 → 均匀采样可行视点  $V_t$  → 连接碰撞-free边  $E_t$  → 构建图  $G_t = (V_t, E_t)$

节点特征（论文 Section IV.A）：每个节点  $v'_k \in V'_t$  包含以下 6 个属性：

| 属性    | 符号                               | 含义               | 数据类型 |
|-------|----------------------------------|------------------|------|
| 相对位置  | $(\Delta x_{ik}, \Delta y_{ik})$ | 节点相对于智能体 i 的坐标   | 连续值  |
| 效用值   | $u_k$                            | 节点处可见前沿数量（归一化）   | 连续值  |
| 智能体占用 | $o_k$                            | 是否被当前/其他智能体占用    | 三元信号 |
| 路标信号  | $g_k$                            | 是否在到最近前沿的 A* 路径上 | 二进制  |
| 信息性朝向 | $h_k$                            | 最大化可见前沿的方向（归一化）  | 连续值  |

前沿分布特征（论文 Section IV.A）：

- 每个节点周围采样 **36 个均匀分布的视场方向**
- 记录每个方向内可观测前沿的归一化值
- 形成 **36 维前沿分布向量**  $F_t$

2.4 动作空间

原始动作空间：所有相邻节点  $(v_j, \psi_i(t)) \in E_t$

动作剪枝策略（论文 Section IV.A - 关键创新）：

1. 对每个相邻节点，基于可观测前沿数量选择  $x$  个最佳朝向（ $x=3$ ）

2. 形成联合动作对  $(v\_j, a\_q)$ ，其中  $a\_q \in \{a\_1, a\_2, a\_3\}$

3. 若无前沿可见，使用 A\* 路径采样朝向
  - 若  $v\_j$  在 A\* 路径上，朝向与路径对齐
  - 否则，指向最近的 A\* 节点

协调机制：若多个智能体选择同一视点，重路由到最近的空闲节点

2.5 奖励函数

奖励结构（论文 Section IV.A）：


$$r_i = r_o + a_a \cdot r_h + r_t + r_f$$

| 奖励项    | 符号    | 计算方式                       | 权重  | 作用      |
|--------|-------|----------------------------|-----|---------|
| 观测前沿奖励 | $r_o$ | 新视点处可见前沿数量（归一化）            | 1   | 鼓励探索新区域 |
| 朝向奖励   | $r_h$ | $\cos(\text{与 A* 路径角度偏差})$ | 0.3 | 鼓励平滑轨迹  |
| 团队奖励   | $r_t$ | 团队观测的前沿总数（归一化）             | 1   | 促进协作    |
| 完成奖励   | $r_f$ | +10（任务完成时）                 | 10  | 鼓励任务完成  |

三、多智能体强化学习算法

3.1 算法框架：CTDE（集中训练、分散执行）

架构设计（论文 Section IV.B/C）：





3.2 网络架构

编码器（Encoder）（论文 Section IV.B）

输入特征融合流程：

节点特征（6维）→ Linear层 →  $h_n^1$ （128维）  
前沿分布（36维）→ Conv1d层 →  $h_n^2$ （128维）  
 $h_n^1 \parallel h_n^2 \rightarrow \text{Concat} \rightarrow \text{Linear层} \rightarrow h_n$ （128维）

堆叠图注意力层（6层）：

$h_n \rightarrow \text{Masked Self-Attention} \times 6 \rightarrow \tilde{h}_n$

- 使用图掩码  $M_t$ （邻接矩阵）限制注意力范围
- 每层仅关注邻居节点，但通过多层堆叠逐步聚合非邻居信息
- 最终节点特征  $\tilde{h}_n$  捕获了更广泛的图依赖关系

策略解码器（Policy Decoder）（论文 Section IV.B）

输入：

- 查询向量  $h_q = h_c = \tilde{h}_n^{\psi_i(t)}$ （当前节点特征）
- 邻居特征  $\tilde{h}_n^e$

朝向特征增强：

1. 离散化朝向空间为 36 个均匀 bin  
2. 计算每个朝向是否在 FoV 内（二进制向量）→ FFN →  $h_h^a$

3. 计算每个节点的历史朝向访问记录（36维向量） $\rightarrow$  FFN  $\rightarrow h_h^e$

4. 邻居特征复制  $x$  次（ $x=3$ ），与  $h_h^a$ 、 $h_h^e$  拼接

5. 拼接结果  $\rightarrow$  FFN  $\rightarrow$  增强邻居特征  $\tilde{h}_h^e$

单头注意力策略输出：

$$h_c, \text{ 增强邻居特征 } \tilde{h}_h^e \rightarrow \text{Single-Head Attention} \rightarrow \pi_{\theta}(a_{\{i,t\}} \mid o_{\{i,t\}}) = w_{\{i,j\}}$$

- 注意力分数直接作为策略概率
- 动态适应不同数量的邻居节点

Critic 解码器（Critic Decoder）（论文 Section IV.C）

关键设计：特权学习（Privileged Learning）

- 训练时：接收完整 Ground Truth 信息（全局地图/完整图）
- 执行时：仅使用局部观测

多智能体注意力机制（论文 Section IV.C）：

1. 获取其他智能体的当前节点特征： $\tilde{h}_n^{\{\psi_{-i}(t)\}}$

2. 获取其他智能体的下一节点特征： $\tilde{h}_n^{\{\psi_{-i}(t+1)\}}$

3. 作为 key-value pairs 增强当前节点特征  $h_c$

4. 增强特征 + 增强邻居特征  $\tilde{h}_h^e \rightarrow$  FFN  $\rightarrow Q_{\phi}(s_t, a_t)$

设计意图：通过融合其他智能体的动作信息，增强信用分配（Credit Assignment）能力

3.3 训练算法：Soft Actor-Critic (SAC)

算法原理（论文 Section IV.C）：

目标函数（最大熵强化学习）：

$$J(\pi) = \mathbb{E}[Q(s, a) - \alpha \cdot \log \pi(a|s)]$$

训练流程：

| 步骤     | 操作             | 频率 | 代码位置                                                                                   |
|--------|----------------|----|----------------------------------------------------------------------------------------|
| 策略更新   | 最大化 $J(\pi)$   | 每步 | [driver.py#L257-L266](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L257-L266) |
| Q网络更新  | 最小化 MSE 损失     | 每步 | [driver.py#L278-L296](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L278-L296) |
| 温度参数更新 | 自适应调整 $\alpha$ | 每步 | [driver.py#L298-L303](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L298-L303) |

| 步骤      | 操作    | 频率           | 代码位置                                                                                   |
|---------|-------|--------------|----------------------------------------------------------------------------------------|
| 目标Q网络更新 | 同步权重  | 每 64 次更新     | [driver.py#L334-L340](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L334-L340) |
| 模型保存    | 保存检查点 | 每 32 episode | [driver.py#L343-L357](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L343-L357) |

训练参数（论文 Section IV.C）：

| 参数            | 值                    | 说明       |
|---------------|----------------------|----------|
| 最大 episode 长度 | 128 步                | 每集步数     |
| 折扣因子 $\gamma$ | 1                    | 无折扣      |
| 批次大小          | 256                  | 训练批次     |
| 回放缓冲区         | 10,000               | 经验池大小    |
| 学习率           | $10^{-5}$            | Adam 优化器 |
| 目标熵           | $0.01 \cdot \log(k)$ | 最大熵目标    |
| 训练地图数         | 5,663                | 训练集规模    |
| 测试地图数         | 100                  | 测试集规模    |

3.4 多智能体协作机制

协同策略（论文 Section IV）：

- 1. **隐式通信**：通过共享策略和集中式 Critic 实现
- 2. **动作剪枝**：基于信息增益选择有意义的动作对
- 3. **碰撞避免**：到达时间排序 + 重路由机制
- 4. **团队奖励**：共享奖励信号促进协作

四、论文改进部分分析

4.1 传统方法的局限性

根据论文 Section II 相关工作分析，传统多机器人探索方法存在以下关键局限：

前沿-based 方法的问题

| 方法      | 代表工作 | 局限性              | 论文引用                                                                             |
|---------|------|------------------|----------------------------------------------------------------------------------|
| Nearest | [9]  | 短视策略，导致重复访问已探索区域 | "Nearest method perform poorly, likely due to their short-sighted strategies"    |
| MMPF    | [15] | 局部探索为主，缺乏全局协调能力  | "MMPF's focus on local exploration further hinders effective agent coordination" |

| 方法            | 代表工作 | 局限性                  | 论文引用                                                                                              |
|---------------|------|----------------------|---------------------------------------------------------------------------------------------------|
| NBVP          | [8]  | 采样效率随环境规模下降，计算成本高    | "NBVP faces challenges in larger environments due to its sampling-based approach"                 |
| Voronoi-based | [16] | 仅关注短期规划，难以处理复杂多智能体交互 | "focus on short-term planning, limiting their ability to handle complex multi-agent interactions" |

基于学习方法的问题

| 问题类型 | 具体描述                  | 论文引用                                                                   |
|------|-----------------------|------------------------------------------------------------------------|
| 受限视场 | 受限视场传感器使动作空间更庞大，决策更困难 | "Constrained FoV sensors further complicate viewpoint planning"        |
| 稀疏奖励 | 传感器约束限制前沿检测频率，学习困难    | "Sparse rewards... heighten the learning difficulties"                 |
| 信用分配 | 团队奖励难以合理归因到单个智能体      | "Reward assignment is also challenging, requiring careful attribution" |
| 时空短视 | 需平衡当前视角利用与长期探索        | "Addressing both spatial and temporal short-sightedness"               |
| 环境规模 | 现有方法局限于小规模环境，缺乏复杂拓扑   | "they are usually confined to small-scale environments"                |

4.2 MARVEL 的改进方案

改进1：图注意力网络（Section IV.B）

针对问题：传统方法难以建模复杂空间关系和大规模环境

改进方案：

传统方法：启发式规则 / CNN（难以捕捉图结构）

↓

MARVEL：6层堆叠图注意力网络

↓

优势：显式建模节点间关系，逐步聚合非邻居信息

技术细节：

- 使用图掩码  $M_t$ （邻接矩阵）限制每层注意力范围
- 通过多层堆叠实现长距离依赖建模
- 节点特征从6维增强到128维，提升表达能力

对比优势：

| 维度    | 传统方法   | MARVEL         |
|-------|--------|----------------|
| 空间关系  | 隐式学习   | 显式建模（图注意力）     |
| 环境规模  | 局限于小规模 | 支持90m×90m大规模环境 |
| 拓扑复杂性 | 处理能力有限 | 有效处理复杂拓扑       |

改进2：前沿-朝向特征融合（Section IV.B）

针对问题：Learnt-Greedy 方法在处理小分散前沿时表现不佳（论文 Section V.A）

论文对比描述：

"learnt-greedy methods delivers faster coverage of 90% of the environment than nearest and MMPF, indicating the strong performance of graph-based attention networks in learning spatial relationship for exploration tasks. However, this method struggles with small scattered frontiers, produced due to suboptimal viewpoint orientations, leading to repeated revisits and longer trajectories for task completion."

改进方案：

Learnt-Greedy：仅使用节点特征，朝向信息不足

↓

MARVEL：智能融合前沿分布 + 朝向特征

↓

优势：增强环境理解，实现非短视规划

技术细节：

- 前沿分布特征：36维向量，编码每个方向的前沿可见度
- 朝向特征：
  - FoV内朝向二进制向量（36维）
  - 历史朝向访问记录（36维）
- 融合方式：Conv1d 编码前沿分布 + FFN 编码朝向信息

对比优势：


| 指标         | Learnt-Greedy | MARVEL | 提升    |
|------------|---------------|--------|-------|
| 轨迹长度（4智能体） | 433.03        | 357.5  | 14.2% |
| 90%覆盖      | 318.46        | 294.21 | 7.6%  |
| 成功率        | 92%           | 100%   | +8%   |

改进3：信息驱动动作剪枝（Section IV.A）

针对问题：受限视场下动作空间过大（位置+朝向联合决策）

改进方案：





技术细节：

- 对每个相邻节点，基于可见前沿数量选择 **3个最佳朝向**
- 形成联合动作对  $(v_j, a_q)$ ，其中  $a_q \in \{a_1, a_2, a_3\}$
- 无前沿可见时，使用 A\* 路径采样朝向

对比优势：

| 维度   | 传统方法       | MARVEL        |
|------|------------|---------------|
| 动作空间 | 固定且庞大      | 动态剪枝（缩小3倍以上）  |
| 计算效率 | 随节点数线性增长   | 保持恒定（0.2s/决策） |
| 决策质量 | 可能选择无信息量动作 | 仅选择高信息动作      |

改进4：特权学习 Critic（Section IV.C）

针对问题：多智能体信用分配困难

改进方案：



技术细节：

- **训练时**：接收完整全局地图和完整图信息
- **执行时**：仅使用局部观测
- **多智能体注意力**：融合其他智能体的当前/下一节点特征

对比优势：

| 维度    | 传统方法       | MARVEL     |
|-------|------------|------------|
| 信用分配  | 困难（局部信息有限） | 增强（全局信息辅助） |
| 训练稳定性 | 可能不稳定      | 更稳定（特权学习）  |
| 协作能力  | 有限         | 更强（MAAC架构） |

改进5：MAAC 多智能体注意力 Critic (Section IV.C)

针对问题：智能体间缺乏有效协调机制

改进方案：



技术细节：

- 基于 MAAC (Multi-Agent Actor-Attention-Critic) [32]
- Critic 融合其他智能体的动作信息作为 key-value pairs
- 增强当前智能体的决策能力

对比优势：

| 维度    | 传统方法               | MARVEL       |
|-------|--------------------|--------------|
| 智能体通信 | 显式或无               | 隐式（通过Critic） |
| 团队协作  | 有限                 | 更强           |
| 重叠率   | 较高（Nearest: 0.693） | 较低（0.170）    |

4.3 改进效果总结

论文实验验证 (Table I)：

| 对比维度       | MARVEL vs 最佳基线         | 提升幅度   |
|------------|------------------------|--------|
| 轨迹长度（2智能体） | 505.25 vs 533.94（NBVP） | 5.4%   |
| 轨迹长度（4智能体） | 357.5 vs 416.50（NBVP）  | 14.2%  |
| 轨迹长度（8智能体） | 279.35 vs 311.21（MMPF） | 10.2%  |
| 成功率        | 100% vs 100%（NBVP）     | 持平     |
| 稳定性（方差）    | 最低                     | 优于所有基线 |

论文关键结论 (Section V.A)：

"MARVEL achieves consistent computation times under 0.2s per decision across all scenarios."

"MARVEL's attention-based neural network, with intelligent fusion of frontiers and orientation information, enhances large environmental understanding and enabling efficient, non-myopic planning."

五、算法创新点总结

5.1 技术贡献

| 创新点         | 论文位置         | 技术细节                       | 核心价值      |
|-------------|--------------|----------------------------|-----------|
| 图注意力网络      | Section IV.B | 6层堆叠图注意力，基于邻接矩阵掩码          | 增强空间关系建模  |
| 前沿-朝向特征融合   | Section IV.B | Conv1d 编码前沿分布 + FFN 编码朝向信息 | 提高环境理解    |
| 信息驱动动作剪枝    | Section IV.A | 基于可见前沿数量选择最佳朝向，减少动作空间      | 解决大动作空间问题 |
| 特权学习 Critic | Section IV.C | 训练时使用全局信息，增强信用分配           | 提高训练稳定性   |
| MAAC 架构     | Section IV.C | 融合其他智能体动作信息的集中式 Critic     | 增强多智能体协作  |

4.2 算法优势

| 维度    | MARVEL            | 传统方法      |
|-------|-------------------|-----------|
| 视场约束  | 显式建模受限 FoV        | 假设全向传感器   |
| 动作空间  | 动态剪枝（3个朝向/节点）     | 固定离散/连续   |
| 空间关系  | 图注意力显式建模          | 隐式学习      |
| 智能体协作 | 集中式 Critic + 团队奖励 | 独立决策或显式通信 |
| 泛化能力  | 无需重新训练适配不同配置      | 需重新调参     |

五、实验结果

5.1 性能对比（论文 Table I）

4智能体场景（FoV=120°, 范围=10m）:

| 指标      | Nearest | MMPF   | NBVP   | Learnt-Greedy | MARVEL        |
|---------|---------|--------|--------|---------------|---------------|
| 轨迹长度 ↓  | 417.92  | 427.30 | 416.50 | 433.03        | <b>357.5</b>  |
| 90%覆盖 ↓ | 346.50  | 358.56 | 329.75 | 318.46        | <b>294.21</b> |
| 重叠率 ↓   | 0.693   | 0.075  | 0.246  | 0.191         | <b>0.170</b>  |
| 成功率 ↑   | 99%     | 95%    | 100%   | 92%           | <b>100%</b>   |

结果分析:

- MARVEL 在轨迹长度上比最佳基线 NBVP 提升 **14.2%**
- 成功率达到 **100%**，表现出卓越的鲁棒性

- 重叠率较低，说明智能体协作效率高

5.2 适配性验证（论文 Table II/III）

不同视场角（4智能体，范围=10m）：

| FoV  | 轨迹长度   | 90%覆盖  | 成功率  |
|------|--------|--------|------|
| 90°  | 378.99 | 313.67 | 100% |
| 120° | 357.5  | 294.21 | 100% |
| 180° | 328.36 | 273.18 | 100% |

不同传感器范围（4智能体，FoV=120°）：

| 范围  | 轨迹长度   | 90%覆盖  | 重叠率   |
|-----|--------|--------|-------|
| 10m | 357.5  | 294.21 | 0.170 |
| 12m | 299.57 | 247.93 | 0.223 |
| 15m | 258.35 | 212.85 | 0.208 |

结论：MARVEL 无需重新训练即可适配不同传感器配置，表现出良好的泛化能力。

5.3 真实硬件验证

论文在 4 架 Crazyflie 2.1 无人机上进行了真实实验，验证了 MARVEL 在实际硬件上的可行性。

六、代码实现对应关系

6.1 网络架构代码

| 组件                  | 代码位置                                                                                           | 说明             |
|---------------------|------------------------------------------------------------------------------------------------|----------------|
| PolicyNet           | [model.py#L198-L283]<br>(file:///C:/Users/Lenovo/Desktop/MARVEL-main/utils/model.py#L198-L283) | 策略网络，包含编码器和解码器 |
| QNet                | [model.py#L286-L392]<br>(file:///C:/Users/Lenovo/Desktop/MARVEL-main/utils/model.py#L286-L392) | Q值网络，支持MAAC模式  |
| SingleHeadAttention | [model.py](file:///C:/Users/Lenovo/Desktop/MARVEL-main/utils/model.py)                         | 指针网络，用于动作选择    |
| MultiHeadAttention  | [model.py](file:///C:/Users/Lenovo/Desktop/MARVEL-main/utils/model.py)                         | 图注意力，用于节点特征增强  |

6.2 训练流程代码

| 组件      | 代码位置                                                                                   | 说明        |
|---------|----------------------------------------------------------------------------------------|-----------|
| 训练主循环   | [driver.py#L145-L358](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L145-L358) | 分布式训练循环   |
| 经验回放缓冲区 | [driver.py#L139-L141](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L139-L141) | 40层多维缓冲区  |
| 策略更新    | [driver.py#L257-L266](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L257-L266) | SAC策略梯度更新 |
| Q网络更新   | [driver.py#L278-L296](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L278-L296) | 双Q网络更新    |
| 温度参数更新  | [driver.py#L298-L303](file:///C:/Users/Lenovo/Desktop/MARVEL-main/driver.py#L298-L303) | 自适应温度更新   |

6.3 环境组件代码

| 组件      | 代码位置                                                                                                   | 说明                 |
|---------|--------------------------------------------------------------------------------------------------------|--------------------|
| 训练环境    | [utils/env.py](file:///C:/Users/Lenovo/Desktop/MARVEL-main/utils/env.py)                               | 使用 maps_medium 训练集 |
| 测试环境    | [utils/env_test.py](file:///C:/Users/Lenovo/Desktop/MARVEL-main/utils/env_test.py)                     | 使用 maps_test 测试集   |
| 智能体类    | [utils/agent.py](file:///C:/Users/Lenovo/Desktop/MARVEL-main/utils/agent.py)                           | 智能体状态管理            |
| 传感器模块   | [utils/sensor.py](file:///C:/Users/Lenovo/Desktop/MARVEL-main/utils/sensor.py)                         | FOV传感器模拟           |
| 多智能体工作器 | [utils/multi_agent_worker.py](file:///C:/Users/Lenovo/Desktop/MARVEL-main/utils/multi_agent_worker.py) | 多智能体环境交互           |

七、总结

7.1 核心设计思想

MARVEL 的核心设计体现了**多智能体强化学习**的以下关键思想：

- 1. **CTDE 范式**：集中训练利用全局信息，分散执行保证实时性
- 2. **图神经网络**：将环境建模为图，通过注意力机制捕捉空间关系
- 3. **动作空间优化**：信息驱动剪枝解决受限视场下的大动作空间问题
- 4. **信用分配**：特权学习 Critic 融合其他智能体信息
- 5. **团队协作**：共享奖励 + 碰撞避免机制促进有效协同

7.2 适用场景

MARVEL 适用于以下场景：

- 受限视场传感器的多机器人协同探索
- 大规模室内环境（可达 90m×90m）
- 需要自适应不同团队规模和传感器配置的应用
- 无人机等小型机器人的自主探索任务

### 7.3 未来方向

论文提到未来将扩展到 **3D 环境**，集成高度信息和相关的 FoV 变化，采用稀疏图表示来管理计算需求。

---

报告生成时间：2026年7月20日