



doi:10.3969/j.issn.1006-1010.20251226-0002 中图分类号: TN927+.2

文献标志码: A 文章编号: 1006-1010(2026)03-0142-09

引用格式: 景毅,姜春晓,王佳蔚,等.基于多智能体强化学习的中低轨卫星协同网络通算资源分配方法[J].移动通信,2026,50(3): 142-150.
JING Yi, JIANG Chunxiao, WANG Jiawei, et al. Multi-Agent Reinforcement Learning for Joint Communication-Computation Resource Allocation in MEO-LEO Cooperative Satellite Networks[J]. Mobile Communications, 2026,50(3): 142-150.

基于多智能体强化学习的中低轨卫星协同网络 通算资源分配方法*

景毅¹, 姜春晓^{2**}, 王佳蔚², 孙佳辰¹, 詹亚锋²

(1. 清华大学电子工程系, 北京 100084;

2. 清华大学北京信息科学与技术国家研究中心, 北京 100084)

【摘要】面向星地融合通信与组网场景下的星上边缘计算需求, 研究中低轨卫星协同网络中的任务卸载与通信-计算资源协同优化问题。针对低轨星座拓扑时变、星间链路容量受限以及星上算力异构等特点, 建立了以端到端完成时延为核心的系统模型, 综合刻画任务分片卸载、星间传输、星上计算与结果回传开销, 并引入QoS时延门限与链路超用惩罚构建联合优化问题。为应对在线决策、跨节点耦合与非凸约束导致的求解困难, 提出一种多智能体深度强化学习方法, 将每颗低轨卫星建模为智能体并输出连续卸载比例向量, 实现对多目的节点的比例卸载。仿真结果表明, 在任务负载和链路能力变化情况下, 所提方法在平均时延指标上相较单目的贪婪卸载、均匀分配及随机分配等基线算法分别降低约5%、25%和39%。

【关键词】中低轨卫星协同网络; 星上边缘计算; 计算卸载; 资源分配; 多智能体强化学习

Multi-Agent Reinforcement Learning for Joint Communication-Computation Resource Allocation in MEO-LEO Cooperative Satellite Networks

JING Yi¹, JIANG Chunxiao², WANG Jiawei², SUN Jiachen¹, ZHAN Yafeng²

(1. The Department of Electronic Engineering, Tsinghua University, Beijing 100084, China;

2. Beijing National Research Center for Information Science and Technology, Tsinghua University, Beijing 100084, China)

【Abstract】To support satellite edge computing in satellite-terrestrial integrated communications and networking, this paper investigates joint task offloading and communication-computing resource coordination in mixed medium earth orbit (MEO) and low earth orbit (LEO) satellite networks. Considering the time-varying constellation topology, constrained inter-satellite link (ISL) capacity, and heterogeneous onboard computing capability, we establish an end-to-end completion delay-oriented model that captures task partition offloading, inter-satellite transmission, onboard computation, and result feedback overhead. A joint optimization problem is formulated by incorporating a QoS delay threshold and a link overuse penalty. To address online decision-making with inter-agent coupling and nonconvex constraints, we propose a multi-agent deep reinforcement learning approach, where each LEO satellite is modeled as an agent producing a continuous offloading ratio vector to enable proportional offloading to multiple destinations. Simulations show that, under varying task loads and ISL capacities, the proposed method reduces the average end-to-end completion delay by approximately 5%, 25%, and 39% compared with single-destination greedy offloading, uniform splitting, and random splitting baselines.

【Keywords】MEO-LEO satellite networks; satellite edge computing; computation offloading; resource allocation; multi-agent reinforcement learning

收稿日期: 2025-12-26

*基金项目: 国家自然科学基金委青年科学基金项目(A类)“空间网络通信按需覆盖理论及应用”(62325108); 国家自然科学基金委青年基金项目“卫星互联网航空终端非连续接收机制与极低功耗通用信号处理机理研究”(62501354); 国家自然科学基金委重点基金项目“大规模星座网络化测控通信理论与技术”(62131012)

**通信作者

Related Literature: ◆许柳飞,罗志勇.面向低轨卫星网络的算力路由策略[J].移动通信,2025,49(6): 35-42. ◆商科峰,邹婕妤,刘伟,等.基于时间扩展图的星地融合网络高可靠路由策略[J].移动通信,2025,49(6): 43-51. ◆郑雨昊,唐琴琴,谢人超,等.面向星地融合网络资源优化的智能任务调度机制[J].移动通信,2025,49(6): 52-58. ◆戴翠琴,王泓运,郭浩鹏.面向6G星地融合的QoAIS保障技术研究[J].移动通信,2025,49(6): 83-94. ◆范阡,胡博,梁树豪.星地多维资源异质图表征及传算协同调度方法[J].移动通信,2025,49(6): 115-122. ◆张成晨,王若琳,张爽,等.面向低轨卫星通信的星载核心网部署方法[J].移动通信,2025,49(6): 142-146.

0 引言

星地融合通信与组网正成为面向 6G (Sixth Generation, 第六代移动通信) 的关键网络形态之一, 其目标是在统一的体系架构下实现星基、空基与地面网络的协同覆盖、协同传输和协同服务, 从而为广域连接、应急通信、海洋与极地覆盖、跨域感知与计算等任务提供连续、可编程且可扩展的网络能力^[1-5]。近年来, 低轨卫星星座规模快速扩展, 星间链路构建的网状拓扑使卫星网络逐步具备可路由、可调度、可扩展的组网特征。然而, 低轨网络同时呈现高速运动引起的拓扑强时变、链路容量随几何与调度显著波动、端到端路径频繁重构等典型挑战, 传统静态或弱动态的组网和资源分配机制难以在大规模星座中兼顾时延、可靠性与资源利用效率^[6-9]。

与仅承载转发的传统卫星通信网络不同, 星上边缘计算与空间算力网络概念的提出推动卫星网络从单一的通信网络向通信-计算融合网络发展^[10-13]。在星地融合场景中, 业务不再局限于比特传输, 更多任务具备明显的计算属性, 例如: 面向感知的数据预处理、特征提取与目标检测; 面向网络侧的缓存、编码与安全处理; 面向终端的推理与智能增强服务。此类任务往往对端到端时延与服务确定性更敏感, 且可在星上或星间协同执行。由此引出一个核心问题: 在星间链路与星上算力均受约束且状态随时间变化的条件下, 如何实现面向时延和 QoS (Quality of Service, 服务质量) 要求的任务卸载与资源调度, 使通信链路利用、计算负载均衡与 QoS 违约风险之间达到可控折中^[14-17]。

从组网与管控视角来看, 星地融合网络具有跨域、异构与多时间尺度特征。为提升可管理性与可编程性, 学界提出以软件定义网络与网络功能虚拟化为基础的星地融合网络架构, 通过控制面与数据面解耦实现跨域资源编排、策略快速迭代与按需服务部署^[18-21]。在低轨星座中, 控制域划分、多控制器协同部署、路由和调度策略的下发与更新等问题直接影响网络的可扩展性及稳定性^[22-25]。此外, 星间路由与拥塞控制在强动态拓扑与长传播时延条件下面临新的困难, 尤其是在业务呈现突发性与空间相关性时, 局部热点可能导致链路拥塞与计算节点过载的耦合放大效应, 进而造成时延显著上升与 QoS 违约概率增加^[26-29]。

综上所述, 星地融合通信与组网研究正在从单纯链路路由优化向分层管控下的跨域资源协同发展: 一是通信侧需要考虑星间链路的容量受限与可用性变化, 构建与路由一致的可达性和资源约束; 二是计算侧需要考虑星上算力异构与计算拥塞的跨节点耦合, 将负载汇聚量化并纳入时延模型; 三是控制侧需要在信令开销受限与状态时变条

件下, 实现可扩展的在线决策机制^[30-33]。在此过程中, 数据驱动的智能优化方法受到关注。例如, 面向软件定义星地融合网络的深度强化学习资源分配研究已显示出在复杂、非凸与动态场景下的自适应潜力^[34-37], 而卫星边缘计算与智能技术融合也被视为提升系统鲁棒性和资源利用效率的重要方向^[38-40]。此外, 结合星间链路的多层学习与协同训练机制, 为跨轨道分层协同提供了基础^[41-42]。

基于此, 本文面向星地融合通信与组网中的分层管控需求, 构建中轨集中式训练与调度、低轨分布式执行的网络架构。该架构以中轨节点作为逻辑控制与训练层, 利用更稳定的资源条件汇聚全局统计信息并进行策略更新; 以低轨卫星作为数据面执行实体, 在轨仅依赖本地可观测状态完成任务卸载决策, 从而在降低控制开销的同时适应低轨拓扑快速变化。进一步地, 本文将每颗低轨卫星建模为一个智能体, 在通信链路与计算资源强耦合约束下进行连续比例卸载决策, 使模型能够统一表征星间传输、星上计算与结果回传对端到端时延和 QoS 的共同影响。本文主要贡献如下:

(1) 提出面向星地融合网络的中轨集中训练/调度-低轨分布执行架构, 并从覆盖、拓扑稳定性与资源条件角度论证中轨控制层的必要性;

(2) 构建通信-计算强耦合的端到端时延模型, 引入与路由一致的链路可达性约束, 并用虚拟队列刻画端口共享导致的链路超用与排队;

(3) 在连续比例卸载决策上设计基于双评论家与目标策略平滑的多智能体 TD3 (Twin Delayed Deep Deterministic Policy Gradient, 双延迟深度确定性策略梯度算法) 训练框架, 提升重载场景下的稳定性与收敛性能;

(4) 在不同业务负载与网络配置下进行仿真对比和权重敏感性分析, 验证所提方法的性能与鲁棒性。

1 系统模型与问题描述

本文采用离散时间建模。时隙索引为 $t \in \mathbb{Z} \geq 0$, 时隙长度为 $\Delta t > 0$ 。对随机过程的期望记为 $\mathbb{E}[\cdot]$, 时间平均采用 $\limsup_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} (\cdot)$ 表示。

1.1 系统架构

如图 1 所示, 低轨卫星集合记为 $\mathcal{N} = \{1, 2, \dots, N\}$, 其中 N 为低轨卫星数量, $i, j \in \mathcal{N}$ 表示具体卫星编号。每颗低轨卫星在每个时隙既可作为任务发起节点, 也可作为任务执行节点。系统采用分层管控: 中轨层承担全局信息汇聚与策略更新, 低轨层在时隙级执行卸载决策。需要注意的是, 本节仅对数据面通信-计算耦合过程建模。




图1 系统模型示意图

采用 MEO (Medium Earth Orbit, 中地球轨道) 作为控制和训练层的主要原因包括如下:

(1) 覆盖范围与可见时间更长, 可在较低切换频率下持续汇聚多颗 LEO (Low Earth Orbit, 低地球轨道) 的状态信息;

(2) 相对运动更缓、拓扑变化更平稳, 有利于构建全局状态并提升策略训练稳定性;

(3) MEO 平台在算力、存储、能量资源上通常更充裕, 更适合承担集中训练与参数广播;

(4) 控制面与数据面解耦后, LEO 仅需执行策略推理与局部转发, 可降低实时控制开销。

低轨星间互联抽象为时变有向图 $\mathcal{G}(t) = \mathcal{N}, \mathcal{E}(t)$, 其中 $\mathcal{E}(t) \subseteq \mathcal{N} \times \mathcal{N}$ 为时隙 t 可用星间链路集合。定义链路可达性指示函数为:

$$\chi_{i,j}(t) = \begin{cases} 1, & (i,j) \in \mathcal{E}(t) \\ 0, & (i,j) \notin \mathcal{E}(t) \end{cases} \quad (1)$$

并约定本地执行始终可用, 即 $\chi_{i,i}(t) = 1, \forall i, t$ 。

1.2 通信模型

对于任意 (i, j) 满足 $\chi_{i,j}(t) = 1$, 定义链路等效可达速率为 $R_{i,j}(t) > 0$ 。若 $\chi_{i,j}(t) = 0$, 则链路不可用且不允许在该方向上传输。

在时隙 t 内, 节点 i 产生输入数据量 $B_i(t) \geq 0$, 任务允许分片并卸载至多个执行节点。定义卸载比例矩阵为:

$$\mathbf{X}(t) = x_{i,j}(t)_{i,j \in \mathcal{N}} \quad (2)$$

其中, $x_{i,j}(t) \in [0, 1]$ 表示节点 i 的任务分配至节点 j 的比例, 分片发送数据量为 $x_{i,j}(t)B_i(t)$ 。

对于 $i \neq j$ 且 $\chi_{i,j}(t) = 1$, 定义传输时延为:

$$T_{i \rightarrow j}^{\text{tx}}(t) = \frac{x_{i,j}(t)B_i(t)}{R_{i,j}(t)} \quad (3)$$

对于本地执行 $j=i$, 定义 $T_{i \rightarrow i}^{\text{tx}}(t) = 0$ 。

为刻画结果回传, 设回传比例为 $\rho \in (0, 1)$, 即结果数据量为 $\rho x_{i,j}(t)B_i(t)$ 。当 $i \neq j$ 且 $\chi_{j,i}(t) = 1$ 时, 则回传时延为:

$$T_{j \rightarrow i}^{\text{ret}}(t) = \frac{\rho x_{i,j}(t)B_i(t)}{R_{j,i}(t)} \quad (4)$$

对于 $j=i$, 定义 $T_{i \rightarrow i}^{\text{ret}}(t) = 0$ 。

为度量链路资源紧张引发的跨隙排队风险, 引入正部算子 $\text{pos}[z] \triangleq \max\{z, 0\}$, 并定义节点 i 的发送超量为:

$$U_i(t) = \sum_{j \in \mathcal{N} \setminus \{i\}} \text{pos}[T_{i \rightarrow j}^{\text{tx}}(t) - \Delta t] \quad (5)$$

1.3 计算模型

节点 i 的计算强度记为 $\kappa_i(t) \geq 0$, 则其任务计算量为 $C_i(t) = B_i(t)\kappa_i(t)$; 节点 j 的可用计算能力记为 $F_j(t) > 0$ 。

在卸载矩阵 $\mathbf{X}(t)$ 给定时, 节点 j 在时隙 t 内汇聚的总到达计算量为:

$$C_j^{\text{in}}(t) = \sum_{i \in \mathcal{N}} x_{i,j}(t)C_i(t) \quad (6)$$

采用时隙内流体服务近似, 节点 j 的计算处理时延定义为:

$$T_j^{\text{comp}}(t) = \frac{C_j^{\text{in}}(t)}{F_j(t)} \quad (7)$$

1.4 时延模型

设与卸载决策无关的固定开销为 $T^{\text{fix}} \geq 0$, 用于表征协议处理、解析与调度等固定时延。任务 i 分片后并行传输与并行计算, 但业务完成由最慢分支决定。定义有效分支集合为:

$$\mathcal{S}_i(t) = \{j \in \mathcal{N} | x_{i,j}(t) > 0\} \quad (8)$$

则节点 i 在时隙 t 的端到端完成时延定义为:

$$T_i(t) = T^{\text{fix}} + \max_{j \in \mathcal{S}_i(t)} (T_{i \rightarrow j}^{\text{tx}}(t) + T_j^{\text{comp}}(t) + T_{j \rightarrow i}^{\text{ret}}(t)) \quad (9)$$

给定 QoS 时延门限 $T^{\text{max}} > 0$, 定义时延超限量为:

$$E_i(t) = \text{pos}[T_i(t) - T^{\text{max}}] \quad (10)$$

1.5 优化问题

每个时隙 t 的决策变量为卸载比例矩阵 $\mathbf{X}(t)$ 。对于每个任务节点 i , 卸载比例满足单纯形约束:

$$x_{i,j}(t) \geq 0, \sum_{j \in \mathcal{N}} x_{i,j}(t) = 1, \forall i \in \mathcal{N} \quad (11)$$

同时, 满足链路可达性约束:

$$x_{i,j}(t) = 0, \forall i \neq j, \forall j \in \mathcal{N} \quad (12)$$

s.t. $\chi_{i,j}(t) = 0$

为统一刻画端到端时延、QoS 超限与链路资源情况,

引入权重系数 $\alpha \geq 0, \beta \geq 0, \gamma \geq 0$ 。定义时间平均期望代价为:

$$J\{\mathbf{X}(t)\} = \limsup_{T \rightarrow \infty} \frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E} \left[\frac{1}{N} \sum_{i \in \mathcal{N}} \alpha T_i(t) + \beta E_i(t) + \gamma U_i(t) \right] \quad (13)$$

因此, 联合通信 - 计算卸载优化问题可表示为:

$$\begin{aligned} \min_{\{X(t)\}} J\{X(t)\} \\ \text{s.t. } x_{i,j}(t) \geq 0, \sum_{j \in \mathcal{N}} x_{i,j}(t) = 1, \forall i \in \mathcal{N} \\ x_{i,j}(t) = 0, \forall i \neq j, \forall j \in \mathcal{N} \end{aligned} \quad (14)$$

在上述模型与问题中, 通信侧由 $\{R_{i,j}(t)\}$ 与 $\{U_i(t)\}$ 表征, 计算侧由 $\{F_i(t)\}$ 与 $\{T_j^{\text{comp}}(t)\}$ 表征, 业务侧由 $\{B_i(t)\}$ 、 $\{\kappa_i(t)\}$ 与 T^{max} 表征, 决策由 $X(t)$ 给出。

2 算法设计

2.1 马尔可夫建模

针对前文给出的时隙级在线联合卸载优化问题, 本节将每个时隙的卸载比例矩阵 $X(t)$ 作为控制量, 构建 MDP (Markov Decision Process, 马尔可夫决策过程) 为:

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, P, r, \gamma_d \rangle \quad (15)$$

其中, $\mathcal{S}$ 为状态空间, $\mathcal{A}$ 为动作空间, P 为状态转移核, r 为单时隙回报函数, $\gamma_d \in (0, 1)$ 为折扣因子。

(1) 状态

时隙 t 的全局状态 $s(t) \in \mathcal{S}$ 由任务到达、计算资源与链路状态共同构成, 可表示为:

$$s(t) = \{B_i(t), \kappa_i(t)\}_{i \in \mathcal{N}}, \{F_i(t)\}_{i \in \mathcal{N}}, \{R_{i,j}(t), \chi_{i,j}(t)\}_{i,j \in \mathcal{N}} \quad (16)$$

执行阶段采用分布式自治: 低轨卫星 i 在轨仅依赖其局部观测 $o_i(t)$ 进行决策。考虑在轨可观测性与可实现性, 可取:

$$o_i(t) = B_i(t), \kappa_i(t), F_i(t), \{R_{i,j}(t), \chi_{i,j}(t)\}_{j \in \mathcal{N}} \quad (17)$$

即由本地任务、算力状态与到各潜在目的节点的链路状态组成。

(2) 动作

将每颗低轨卫星建模为一个智能体, 则智能体 i 在时隙 t 输出卸载比例向量为:

$$\mathbf{a}_i(t) \triangleq \mathbf{x}_i(t) = x_{i,1}(t), \dots, x_{i,N}(t) \quad (18)$$

所有智能体的联合动作记为 $\mathbf{a}(t) = [a_1(t), \dots, a_N(t)]$, 并与卸载矩阵满足 $X(t) = [x_{i,j}(t)]$ 一一对应。

由前文约束可知, 动作必须同时满足单纯形与可达性约束。为进一步贴近可达候选集合的现实限制, 并降低大规模星座下的动作维度, 引入候选目的集合约束: 对于每个 i , 在时隙 t 构造 $\mathcal{A}_i(t) \subseteq \mathcal{N}, i \in \mathcal{A}_i(t), j \in \mathcal{A}_i(t) \Rightarrow \chi_{i,j}(t) = 1$, 并要求 $x_{i,j}(t) = 0, \forall j \notin \mathcal{A}_i(t)$ 。

在仿真中, $\mathcal{A}_i(t)$ 可由路由或 Top- K 可达邻居 (如按 $R_{i,j}(t)$ 选取 K 个最大者) 生成。

(3) 状态转移与回报

状态转移满足 $s(t+1) \sim P|s(t), \mathbf{a}(t)$, 其由业务到达、链路可达、算力变化等共同驱动。本节中不显式建模 P , 而通过交互样本进行模型自由学习。定义单时隙系统代价为:

$$g(t) = \frac{1}{N} \sum_{i \in \mathcal{N}} \alpha T_i(t) + \beta E_i(t) + \gamma U_i(t) \quad (19)$$

令共享回报为 $r(t) = -g(t)$ 。此外, 为抑制训练初期出

现极端退化策略, 在训练时引入熵正则项:

$$r_{\text{train}}(t) = -g(t) + \lambda_{\text{ent}} \cdot \frac{1}{N} \sum_{i \in \mathcal{N}} H \mathbf{x}_i(t) \quad (20)$$

$$H(\mathbf{x}) = -\sum_j x_j \log(x_j + \epsilon) \quad (21)$$

其中, $\lambda_{\text{ent}} \geq 0$ 为权重, ϵ 为数值稳定常数。学习目标为最大化折扣累积期望回报 $\mathbb{E}[\sum_{t=0}^{\infty} \gamma_d^t r_{\text{train}}(t)]$, 从而在长期意义下逼近优化目标最小化。

2.2 多智能体强化学习算法框架

在上述 MDP 定义基础上, 为匹配图 2 所示的中轨卫星集中训练、低轨卫星分布式执行的资源调度网络架构, 采用多智能体强化学习方法中的执行者-评论家框架。其核心思想是: 执行阶段每颗低轨卫星仅利用局部观测 $o_i(t)$ 输出可行卸载比例; 训练阶段在中轨侧利用全局状态 $s(t)$ 与联合动作 $\mathbf{a}(t)$ 进行集中式价值评估, 以稳定学习并刻画跨节点信息耦合。




图2 中低轨卫星协同资源调度网络架构示意图

图 3 给出了算法的闭环流程。下面按执行→交互→回放→训练→下发的顺序介绍算法各组成模块。




图3 多智能体强化学习算法流程图

(1) 策略生成与输出

每个智能体 i 采用确定性策略网络 (执行者) 生成未约束打分向量 (logits) 为:

$$\mathbf{z}_i(t) = f_{\theta_i} o_i(t) \in \mathbb{R}^N \quad (22)$$

其中, θ_i 为策略参数。将约束处理显式嵌入动作映射, 定义掩码向量 $\mathbf{m}_i(t) \in \{0, 1\}^N$:

$$m_{i,j}(t) = \begin{cases} 1, & j \in \mathcal{A}_i(t) \\ 0, & j \notin \mathcal{A}_i(t) \end{cases} \quad (23)$$

并保证 $m_{i,i}(t)=1$ 。因此，构造可行化映射 $\Psi(\cdot)$ ：

$$x_{i,j}(t) = \Psi_j z_i(t) \quad (24)$$

$$m_i(t) = \frac{m_{i,j}(t) \exp(z_{i,j}(t))}{\sum_{k \in \mathcal{N}} m_{i,k}(t) \exp(z_{i,k}(t))} \quad (25)$$

由此可直接保证： $x_{i,j}(t) \geq 0$ 、 $\sum_j x_{i,j}(t) = 1$ ，且对不可达 / 非候选目的节点自动满足 $x_{i,j}(t) = 0$ 。因此，策略网络无需再学会不违反约束，而是通过结构化映射确保每一步输出均可执行，从而显著提升训练稳定性与工程可落地性。

(2) 交互与经验回放

在执行阶段，各智能体得到 $\mathbf{x}_i(t)$ 后形成联合动作 $\mathbf{a}(t)$ 并与环境交互，环境依据前文模型计算 $T_i(t)$ 、 $E_i(t)$ 、 $U_i(t)$ ，进而得到回报 $r_{\text{train}}(t)$ 并转移到 $s(t+1)$ 。将 $s(t), \mathbf{o}(t), \mathbf{a}(t), r_{\text{train}}(t), s(t+1), \mathbf{o}(t+1)$ 写入经验回放池 $\mathcal{D}$ ，其中 $\mathbf{o}(t) = [o_1(t), \dots, o_N(t)]$ 。

(3) 目标动作构造

训练阶段在中轨侧引入集中式动作价值函数（评论家）以刻画跨节点耦合。为降低函数逼近误差导致的过估计偏差，采用双评论家结构： $Q_{\phi^{(1)}}(s(t), \mathbf{a}(t)), Q_{\phi^{(2)}}(s(t), \mathbf{a}(t))$ ，并设置对应的目标网络参数 $\bar{Q}_i, \bar{\phi}_i^{(1)}, \bar{\phi}_i^{(2)}$ 。

为构造贝尔曼目标，先用目标策略生成下一步目标动作，并采用目标策略平滑：对每个 i 加入裁剪噪声 ξ_i ($\|\xi_i\|_\infty \leq c$)，再经可行化映射投影回可行域：

$$\tilde{\mathbf{x}}_i(t+1) = \Psi(f_{\bar{Q}_i} o_i(t+1) + \xi_i(t), m_i(t+1)) \quad (26)$$

联合目标动作作为：

$$\tilde{\mathbf{a}}(t+1) = [\tilde{\mathbf{x}}_1(t+1), \dots, \tilde{\mathbf{x}}_N(t+1)] \quad (27)$$

因此，定义目标值为：

$$y_i(t) = r_{\text{train}}(t) + \gamma_d \cdot \min_{k \in \{1,2\}} Q_{\bar{\phi}_i^{(k)}}(s(t+1), \tilde{\mathbf{a}}(t+1)) \quad (28)$$

(4) 评论家与策略更新

对于 $k \in \{1, 2\}$ ，评论家通过最小化平方贝尔曼残差更新：

$$\mathcal{L}_i^{(k)} = \mathbb{E}_{\mathcal{D}} [Q_{\phi_i^{(k)}}(s(t), \mathbf{a}(t)) - y_i(t)]^2 \quad (29)$$

策略更新采用确定性策略梯度形式。为保持集中训练的可操作性，在回放样本中固定其他智能体动作 $\mathbf{a}_{-i}(t)$ ，仅将第 i 个动作替换为当前策略输出 $\pi_{\theta_i}(o_i(t))$ ，并最大化评论家值为：

$$J_i(\theta_i) = \mathbb{E}_{\mathcal{D}} [Q_{\phi_i^{(1)}}(s(t), \mathbf{a}_{-i}(t), \pi_{\theta_i}(o_i(t)))] \quad (30)$$

为降低策略更新对评论家估计误差的敏感性，采用延迟策略更新：每进行 d 次评论家更新，再进行一次策略更新（典型 TD3 机制）。随后对目标网络进行软更新： $\bar{\theta}_i \leftarrow (1-\tau)\bar{\theta}_i + \tau\theta_i, \bar{\phi}_i^{(k)} \leftarrow (1-\tau)\bar{\phi}_i^{(k)} + \tau\phi_i^{(k)}, k \in \{1, 2\}$ ，其中 $\tau \in (0, 1)$ 为软更新系数。上述双评论家、目标策略平滑、延迟更新、软更新组合可显著提升连续动作学习的稳定性与可复现性。

(5) 复杂度分析

若不加约束，联合动作维度为 N^2 ，集中式评论家输入随星座规模快速膨胀。引入候选集约束并令 $|\mathcal{A}_i(t)| = K \ll N$ 时，每个智能体有效输出维度由 N 降为 K ，联合动作由 N^2 降为 NK ，从而显著降低训练与推理开销，并与可达候选集一致。

针对更大规模星座时的可扩展性问题：（1）可将候选集合从静态 top- K 扩展为基于可达性及距离 / 负载的动态稀疏集合，从而保持动作维度线性增长；（2）集中式价值函数可采用图结构编码对全局状态进行压缩表征，以避免直接拼接带来的维度爆炸；（3）工程实现上可按轨道面 / 区域进行分簇训练与参数共享，并由中轨节点进行分簇级参数汇聚与广播，从而实现近似线性扩展。

(6) 算法流程

算法 1 给出多智能体强化学习方法流程，包括执行、回放、集中训练与策略下发闭环，具体如下：

算法 1：基于多智能体强化学习的计算卸载和资源分配方法

1. **Input:** 星座规模 N ，折扣因子 γ_d ，软更新系数 τ ，延迟更新步长 d ，候选集合大小 K ，目标平滑噪声幅度 c ，回放池 $\mathcal{D}$ ，小批量大小 B
2. **初始化:** 各智能体策略网络参数 $\{\theta_i\}$ ，双评论家参数 $\{\phi_i^{(1)}, \phi_i^{(2)}\}$ ；复制目标网络参数 $\bar{\theta}_i \leftarrow \theta_i, \bar{\phi}_i^{(k)} \leftarrow \phi_i^{(k)}$
3. **for** episode=1, 2, ... **do**
4. 重置环境，获得初始状态 $s(0)$ 与观测 $\{o_i(0)\}$
5. **for** $t=0, 1, \dots, T_{\text{ep}}-1$ **do**
6. （执行）为每个智能体 i 构造候选集合 $\mathcal{A}_i(t)$ 并生成掩码 $m_i(t)$
7. $z_i(t) = f_{\theta_i}(o_i(t))$ ，经可行化映射得 $\mathbf{x}_i(t) = \Psi(z_i(t), m_i(t))$
8. 加入探索噪声后再投影回可行域：
9. $\mathbf{x}_i(t) \leftarrow \Psi(z_i(t) + \epsilon_i, m_i(t))$
10. 形成联合动作 $\mathbf{a}(t) = [\mathbf{x}_1(t), \dots, \mathbf{x}_N(t)]$ 并与环境交互
11. 获得 $r_{\text{train}}(t)$ 、 $s(t+1)$ 与 $\{o_i(t+1)\}$ ，将 $(s, \mathbf{o}, \mathbf{a}, r, s', \mathbf{o}')$ 写入回放池 $\mathcal{D}$
12. （集中训练）从 $\mathcal{D}$ 采样小批量 $(s, \mathbf{o}, \mathbf{a}, r, s', \mathbf{o}')$
13. **for** 每个智能体 i **do**
14. 生成目标动作 $\tilde{\mathbf{a}}(t+1)$ ，计算目标值 $y_i(t)$
15. 更新双评论家参数 $\phi_i^{(1)}, \phi_i^{(2)}$
16. **if** 满足 $t \bmod d = 0$ **then**
17. 更新策略参数 θ_i
18. 软更新目标网络参数 $\bar{\theta}_i, \bar{\phi}_i^{(1)}, \bar{\phi}_i^{(2)}$
19. **end if**
20. **end for**
21. （下发）将更新后的 $\{\theta_i\}$ 下发至低轨执行端进入下一时隙
22. **end for**

3 仿真与结果分析

3.1 仿真环境

仿真对象为由 N 颗低轨卫星构成的星上协同计算网络,系统按时隙离散,时隙长度为 Δt ,每个回合包含 T_{ep} 个时隙。在时隙 t 内,卫星 i 产生任务 $B_i(t)$ 和 $\kappa_i(t)$,其中 $B_i(t)$ 为输入数据量, $\kappa_i(t)$ 为单位比特计算强度,计算需求为 $C_i(t) = B_i(t)\kappa_i(t)$ 。卫星 j 的星上可用算力为 $F_j(t)$ 。星间链路由等效速率 $R_{i,j}(t)$ 刻画;回传比例为 ρ , QoS 门限为 T^{max} 。端到端完成时延采用并行分片最大完成时间模型,并以链路超用刻画跨隙拥塞风险。

在实现层面,固定开销 T^{fix} 可对应为上/下行固定处理开销之和,从而与协议处理时延保持一致。仿真关键参数汇总如表 1 所示:

表 1 仿真参数汇总

符号	含义	取值
N	低轨卫星数	6
Δt	时隙长度	1.0 s
T_{ep}	每回合时隙数	60
T^{up}	上行固定开销	0.02 s
T^{down}	下行固定开销	0.02 s
ρ	回传比例	0.05
T^{max}	QoS 时延门限	0.70 s
$B_i(t)$	输入数据量	$\mathcal{N}(8,2) \times 10^6$ bit
$\kappa_i(t)$	计算强度	$\mathcal{N}(800,120)$
$F_j(t)$	星上算力	均匀分布于 $[8, 20] \times 10^9$ cycles/s
$R_{i,j}(t)$	ISL 速率	均匀分布于 $[0.8, 2.8] \times 10^9$ bit/s
W_{delay}	时延权重	1.0
W_{exceed}	超限惩罚权重	4.0
W_{link}	链路超用权重	0.6
W_{ent}	熵正则权	0.10

3.2 对比算法与评价指标

为验证所提方法的有效性,可选取如下基线策略进行对比:

- (1) Local-only: 任务全部在本地处理,不发生跨星卸载;
- (2) Uniform-split: 对可达目的节点均匀分片;
- (3) Random: 在可达集合内随机生成分片比例;
- (4) Greedy (single): 每时隙为每个任务节点选择单一目的节点卸载;
- (5) MADDPG (Multi-Agent Deep Deterministic Policy Gradient, 多智能体深度确定性策略梯度): 集中训练、分布执行框架,采用单评论家与本文所提方法进行对比。
- (6) Proposed (本文所提方法): 输出连续卸载比例向量,允许对多个目的节点进行比例卸载,并在训练阶段采用集中式价值评估以提升稳定性。

对于任务节点 i ,定义其在时隙 t 的可达集合为 $\mathcal{A}_i(t) = \{j \in \mathcal{N} | x_{i,j}(t) = 1\}$,并约定 $i \in \mathcal{A}_i(t)$ 恒成立,则

Uniform-split 的动作定义为:

$$x_{i,j}(t) = \begin{cases} \frac{1}{|\mathcal{A}_i(t)|}, & j \in \mathcal{A}_i(t) \\ 0, & \text{otherwise} \end{cases} \quad (31)$$

Random 采用在 $\mathcal{A}_i(t)$ 上的随机比例向量 (如 Dirichlet 采样) 并在不可达分量处置零后归一化; Greedy (single) 采用最小化瞬时估计完成时延的单目的选择规则。对于任意 $j \in \mathcal{A}_i(t)$,构造在 $x_{i,j}(t)=1$ 假设下的估计完成时延为:

$$\hat{T}_{i \rightarrow j}(t) = T^{\text{fix}} + \frac{B_i(t)}{R_{i,j}(t)} + \frac{C_i(t)}{F_j(t)} + \frac{\rho B_i(t)}{R_{j,i}(t)} \quad (32)$$

当 $j=i$ 时,按前文约定取本地传输与回传时延为 0。

随后再取:

$$j^*(t) = \arg \min_{j \in \mathcal{A}_i(t)} \hat{T}_{i \rightarrow j}(t) \quad (33)$$

令:

$$x_{i,j}(t) = \begin{cases} 1, & j = j^*(t) \\ 0, & j \neq j^*(t) \end{cases} \quad (34)$$

需要说明的是,由于在估计时延时仅使用当前时隙链路速率与算力信息,未考虑多任务同时选择同一目的节点引发的跨任务耦合,因此该类单目的瞬时贪婪策略在重载下更易造成时延显著增大。

评价指标包括平均端到端时延 $\bar{T}$ 以及综合指标 S 。其中, $\bar{T}$ 为回合内按所有任务节点与时隙平均得到的端到端完成时延;综合指标定义为 $S = \bar{T} + \lambda \bar{v}$, $\lambda=0.8$, $\bar{v}$ 为 QoS 违约率 ($T_i(t) > T^{\text{max}}$ 的比例)。该综合指标与训练阶段最优检查点选择的口径一致,用于同时衡量时延水平与违约风险。

3.3 仿真设置

采用单变量扫描以隔离关键因素影响,具体如下:

(1) 任务负载扫描: 设置任务缩放系数为 $\eta_{\text{task}} \in \{1.0, 1.4, 1.8, 2.2\}$,令 $B_i(t) \leftarrow \eta_{\text{task}} B_i(t)$,对应图 4 和图 5;

(2) 链路能力扫描: 设置链路缩放系数为 $\eta_{\text{isl}} \in \{1.0, 1.3, 1.6, 2.0\}$,令 $R_{i,j}(t) \leftarrow \eta_{\text{isl}} R_{i,j}(t)$,对应图 6 和图 7。

除被扫描变量之外,其余参数均取表 1 的基准值。




图4 任务负载变化下的平均时延曲线




图5 任务负载变化下的复合指标分数曲线




图6 链路能力变化下的平均时延曲线




图7 链路能力变化下的复合指标分数曲线

3.4 收敛性分析

本文所提方法采用双评论家、目标策略平滑与延迟策略更新,以提升多智能体学习稳定性;同时,采用复合指标最优检查点及早停机机制避免后期漂移。

在训练过程中,评估阶段的 S 通常呈现先快速下降后趋于平稳的收敛特征,最优检查点多出现在中后期评估回合附近,该现象与连续动作空间下的策略收敛规律一致。本文结果均基于最优检查点,以保证对比的公平性。

3.5 指标随任务负载变化分析

(1) 平均时延 $\bar{T}$

如图4所示,随着 η_{task} 逐渐增大,各方法的 $\bar{T}$ 整体呈单调上升。当轻载 $\eta_{\text{task}}=1.0$ 时,所提方法 $\bar{T}$ 约为 0.53 s,与 Local-only 的约为 0.54 s 接近,表明当协同收益不足时策略不会引入不必要的跨星传输开销;当进入重载 $\eta_{\text{task}}=2.2$ 时,所提方法 $\bar{T}$ 约为 1.08 s,优于 Greedy (single) 的约为 1.12 s、Uniform 的约为 1.44 s 以及 Random 的约为 1.79 s,对应相对下降分别约为 3.6%、25.0% 和 39.7%。

该优势与时延式的 $\max(\cdot)$ 结构直接相关:当多任务在同一时隙集中选择同一执行节点时, $C_j^{\text{in}}(t)$ 增大,使得 $T_j^{\text{comp}}(t)$ 成为主导项,从而显著提升时延。Greedy (single) 方法由于仅输出单目的动作,重载下更易形成任务聚集;相比之下,本文所提方法输出连续比例向量,可将任务在多个可达节点间自适应分担,从机制上抑制任务聚集。Uniform/Random 方法由于忽略链路算力异构,易将分片分配至低速链路或高负载节点,从而导致通信与计算代价叠加。

通过与 MADDPG 基线可见,其在轻载场景下可达到与启发式相近的水平,但在中/重载下收敛速度与最终指标整体不及本文所提方法,进一步验证了所提方法在改进稳定性与性能上的优势。

(2) 复合指标分数 S

复合指标分数对 QoS 风险更敏感。当 $\eta_{\text{task}}=2.2$ 时,所提方法 S 约为 1.75,低于 Greedy (single) 的约为 1.88、Uniform 的约为 2.24 以及 Random 的约为 2.58,相对下降分别约为 6.9%、21.9% 和 32.2%。进一步地,由 $\bar{v}=(S-\bar{T})/\lambda$ 可估计违约率量级:所提方法 $\bar{v}$ 约为 0.84, Greedy (single) 的约为 0.95, Uniform/Random 的接近 1。该结果表明在重载区间,方法间差异主要体现在对违约风险的抑制能力:所提方法通过降低单节点汇聚概率,使得违约率在相同负载下显著低于单目的贪婪策略。

3.6 指标随链路能力变化分析

(1) 平均时延 $\bar{T}$

当 η_{isl} 从 1.0 增至 2.0 时,各方法 $\bar{T}$ 的整体变化相对有限,而方法间差距保持稳定:本文所提方法为 0.525~0.533 s, Greedy (single) 方法为 0.555~0.573 s, Uniform 方法为 0.702~0.712 s, Random 方法为 0.855~0.871 s。该现象表明在表1的设置下系统瓶颈更偏向计算侧的汇聚负载而非链路带宽,链路增强的边际收益受到计算拥塞的约束。

即便如此,本文所提方法相对 Greedy (single) 方法仍保持 5%~8% 的稳定优势,说明其主要收益来自对计算热点的抑制而非仅依赖链路增益。与 MADDPG 基线对比可见,本文所提方法在链路能力变化时的时延和复合分数指标上均表现更优,从而验证了双评论家模式对性能的贡献。

(2) 复合指标分数 S

本文所提方法在链路扫描下 S 为 0.67~0.69,显著低于 Uniform 方法的 1.11~1.15 与 Random 方法的 1.46~1.48。结合图 6 可得违约率量级:所提方法 $\bar{\gamma}$ 为 0.18~0.20,Uniform 方法为 0.51~0.55,Random 方法约为 0.76。这说明在链路条件变化时,所提方法能够稳定维持在较低违约水平,其关键在于:当链路并非主导瓶颈时,策略不会盲目增加跨星卸载,而是以降低汇聚计算拥塞为优先目标,使 QoS 风险在不同 η_{isl} 下保持低波动。

3.7 小结

综合任务负载与链路能力变化分析,可得:

(1) 在基准参数设置下系统性能对计算侧汇聚负载更敏感:当任务负载升高时,各方法的平均时延与违约风险显著上升,而链路带宽提升带来的边际收益相对有限,表明主要瓶颈更偏向星上计算侧的拥塞;

(2) 所提方法在重载区间的优势主要来源于连续比例卸载带来的结构性自由度:通过将任务在多个可达节点间自适应分担,可有效抑制单点热点形成,从而降低时延增长速度,并在综合指标上显著降低 QoS 违约风险;

(3) 链路条件变化下所提方法表现出更小的性能波动与更低的违约水平:说明其策略并非依赖单一链路增益,而是能够在通信与计算资源耦合约束下实现自适应的负载调节和风险控制。

4 结束语

本文面向星地融合通信与组网场景下的星上边缘计算需求,研究低轨卫星网络中的任务卸载与通信-计算资源协同优化问题。针对低轨星座拓扑强时变、星间链路容量受限与星上算力异构并存所导致的跨节点耦合和在线决策难题,本文建立了以端到端完成时延为核心的时隙级系统模型,统一刻画任务分片卸载、星间传输、星上计算与结果回传的综合开销,并进一步引入 QoS 时延门限与链路超用惩罚,构建了面向长期平均性能的联合优化问题。在此基础上,本文提出一种多智能体强化学习方法,训练阶段中轨卫星和地面运控中心集中式评估生成各低轨卫星任务卸载动作;执行阶段各低轨卫星仅基于局部可观测信息输出连续比例卸载决策,从而兼顾在轨自治需求与控制信令开销约束。通过仿真验证了本文所

提方法的有效性和稳定性:一方面,在任务负载增强的高负载区域,所提方法相较仅本地计算、均匀/随机分配及单目的贪婪卸载,能够在显著降低平均端到端时延的同时有效抑制 QoS 违约率;另一方面,所提方法在不同链路条件下均能保持较低的性能波动与违约水平,表明其能够围绕计算侧瓶颈与链路侧约束实现更稳健的权衡,体现出较强的鲁棒性与可迁移性。

在未来的研究中,将重点从以下方向进一步展开:

(1) 面向更大规模星座与更复杂拓扑演化,结合图结构表示与参数共享机制提升可扩展性;(2) 将链路预算、路由与调度过程更紧密地纳入统一决策框架,刻画更真实的跨层耦合;(3) 引入能量约束、任务优先级与不确定业务到达等因素,研究鲁棒、安全的在线协同优化方法,并推动与实际星座数据或在轨试验的验证。

参考文献:

- [1] 中国通信学会. 通感算一体化网络前沿报告[R]. 2021.
- [2] Xie R, Tang Q, Wang Q, et al. Satellite-Terrestrial Integrated Edge Computing Networks: Architecture, Challenges, and Open Issues[J]. IEEE Network, 2020,34(3): 224-231.
- [3] Jing Y, Wang J, Jiang C, et al. Satellite MEC with Federated Learning: Architectures, Technologies and Challenges[J]. IEEE Network, 2022,36(5): 106-112.
- [4] 陈文. 迈向泛在移动智联时代: 6G 卫星互联网[J]. 移动通信, 2025,49(6): 1.
- [5] 刘秉坤,常锴,成婕妍,等. 6G 星地融合网络: 需求、挑战与关键技术[J]. 移动通信, 2025,49(6): 2-10.
- [6] Tang Q, Fei Z, Li B, et al. Computation Offloading in LEO Satellite Networks with Hybrid Cloud and Edge Computing[J]. IEEE Internet of Things Journal, 2021,8(11): 9164-9176.
- [7] Song Z, Hao Y, Liu Y, et al. Energy-Efficient Multiaccess Edge Computing for Terrestrial-Satellite Internet of Things[J]. IEEE Internet of Things Journal, 2021,8(18): 14202-14218.
- [8] 石爽,刘子威,张更新,等. 低轨卫星互联网链路受扰性能分析[J]. 移动通信, 2025,49(6): 19-26.
- [9] 张嘉璇,沈斐,燕锋,等. 巨型低轨卫星星座信道周期性特性研究[J]. 移动通信, 2025,49(6): 59-62.
- [10] Chen, et al. Learning-Based Computation Offloading for IoRT Through Ka/Q-Band Satellite-Terrestrial Integrated Networks[J]. IEEE Internet of Things Journal, 2022,9(14): 12056-12070.
- [11] Bi J, et al. Energy-Minimized Partial Computation Offloading in Satellite-Terrestrial Edge Computing Networks[J]. IEEE Internet of Things Journal, 2025,12(5): 5931-5944.
- [12] 袁野,徐子欣,王正强,等. 6G 卫星互联网应用创新发展策略研究[J]. 移动通信, 2025,49(6): 27-34.
- [13] 覃俊祥,杨志玺,王永刚,等. 弹性卫星通信网络的体系结构、关键技术及抗干扰运用研究[J]. 移动通信, 2025,49(6): 75-82.
- [14] Ding C, Wang J-B, Zhang H, et al. Joint Optimization of Transmission and Computation Resources for Satellite and High Altitude Platform Assisted Edge Computing[J]. IEEE Transactions on Wireless Communications, 2022,21(2): 1362-1377.

- [15] Chai F, Zhang Q, Yao H, et al. Joint Multi-Task Offloading and Resource Allocation for Mobile Edge Computing Systems in Satellite IoT[J]. IEEE Transactions on Vehicular Technology, 2023,72(6): 7783-7795.
- [16] 张恒, 马婷, 陈光霁, 等. 基于联邦学习的空天地一体化网络计算卸载与资源分配方法研究[J]. 移动通信, 2025,49(6): 95-102.
- [17] 范阔, 胡博, 梁树豪. 星地多维资源异质图表征及传算协同调度方法[J]. 移动通信, 2025,49(6): 115-122.
- [18] Qiu C, Yao H, Yu FR, et al. Deep Q-Learning Aided Networking, Caching, and Computing Resources Allocation in Software-Defined Satellite-Terrestrial Networks[J]. IEEE Transactions on Vehicular Technology, 2019,68(6): 5871-5883.
- [19] Chen J-H, Kuo W-C, Liao W. SpaceEdge: Optimizing Service Latency and Sustainability for Space-Centric Task Offloading in LEO Satellite Networks[J]. IEEE Transactions on Wireless Communications, 2024,23(10): 15435-15446.
- [20] 黄婉莹, 陈始茂, 周晓玲, 等. 一种混合粒度的卫星互联网 SDN 控制器部署方法研究[J]. 移动通信, 2025,49(6): 135-141.
- [21] 许柳飞, 罗志勇. 面向低轨卫星网络的算力路由策略[J]. 移动通信, 2025,49(6): 35-42.
- [22] Zhou J, Yang Q, Zhao L, et al. Mobility-Aware Computation Offloading in Satellite Edge Computing Networks[J]. IEEE Transactions on Mobile Computing, 2024,23(10): 9135-9149.
- [23] Lan W, Chen K, Li Y, et al. Deep Reinforcement Learning for Privacy-Preserving Task Offloading in Integrated Satellite-Terrestrial Networks[J]. IEEE Transactions on Mobile Computing, 2024,23(10): 9678-9691.
- [24] 商科峰, 邹婕妤, 刘伟, 等. 基于时间扩展图的星地融合网络高可靠路由策略[J]. 移动通信, 2025,49(6): 43-51.
- [25] 郑雨昊, 唐琴琴, 谢人超, 等. 面向星地融合网络资源优化的智能任务调度机制[J]. 移动通信, 2025,49(6): 52-58.
- [26] Zhou C, et al. Deep Reinforcement Learning for Delay-Oriented IoT Task Scheduling in SAGIN[J]. IEEE Transactions on Wireless Communications, 2021,20(2): 911-925.
- [27] Xie B, Cui H, Ho IW-H, et al. Computation Offloading and Resource Allocation in LEO Satellite-Terrestrial Integrated Networks with System State Delay[J]. IEEE Transactions on Mobile Computing, 2025,24(3): 1372-1385.
- [28] 马昊宇, 郝旭, 褚永超, 等. 面向海域通信的星地融合网络能效优化算法[J]. 移动通信, 2025,49(6): 103-108.
- [29] 薛冠昌, 杨明川, 周必磊, 等. IRS 增强的星地一体化网络频谱共享算法[J]. 移动通信, 2025,49(6): 109-114.
- [30] Lai J, Liu H, Xu G, et al. Joint Computation Offloading and Resource Allocation for LEO Satellite Networks Using Hierarchical Multi-Agent Reinforcement Learning[J]. IEEE Transactions on Cognitive Communications and Networking, 2025,11(4): 2554-2567.
- [31] Xiao Y, et al. SEC-DT: Satellite Edge Computing Enabled Dynamic Data Transmission Based on GNN-Assisted MARL for Earth Observation Missions[J]. IEEE Open Journal of the Communications Society, 2025,6: 288-301.
- [32] 戴翠琴, 王泓运, 郭浩鹏. 面向 6G 星地融合的 QoAIS 保障技术研究[J]. 移动通信, 2025,49(6): 83-94.
- [33] 杨君一, 林琦彬, 范珂欣, 等. 面向大规模低轨星座的用户接入方法研究[J]. 移动通信, 2025,49(6): 123-127.
- [34] 王宇轩, 季钰, 孙耀华. 一种适用于大多普勒场景通信的波形方案[J]. 移动通信, 2025,49(6): 69-74.
- [35] Wu H, Yang X, Bu Z. Task Offloading with Service Migration for Satellite Edge Computing: A Deep Reinforcement Learning Approach[J]. IEEE Access, 2024,12: 25844-25856.
- [36] 郭静, 陈春铸, 魏岳军, 等. 面向 6G 卫星通信的低复杂度比特翻转概率整形方案[J]. 移动通信, 2025,49(6): 128-134.
- [37] Zhang Y, Chen C, Liu L, et al. Aerial Edge Computing on Orbit: A Task Offloading and Allocation Scheme[J]. IEEE Transactions on Network Science and Engineering, 2023,10(1): 275-285.
- [38] Jing Y, Jiang C, Ge N, et al. Resource Optimization for Signal Recognition in Satellite MEC with Federated Learning[C]//2021 13th International Conference on Wireless Communications and Signal Processing (WCSP). Changsha: IEEE, 2021: 1-5.
- [39] 刘言, 朱凯歌, 孙枫, 等. 卫星网络星地协同边缘云服务关键技术[J]. 天地一体化信息网络, 2025,6(3): 30-38.
- [40] 张成晨, 王若琳, 张爽, 等. 面向低轨卫星通信的星载核心网部署方法[J]. 移动通信, 2025,49(6): 142-146.
- [41] 王玉震, 焦凌霄, 童建飞, 等. IoT-NTN TDD 关键技术研究及标准化进展[J]. 移动通信, 2025,49(6): 11-18.
- [42] Xie J, Jia Q, Chen Y, et al. Computation Offloading and Resource Allocation in Satellite-Terrestrial Integrated Networks: A Deep Reinforcement Learning Approach[J]. IEEE Access, 2024,12: 97184-97195. ★

作者简介



景毅：清华大学电子工程系在读博士研究生，主要研究方向为卫星通信、空天地一体化网络、边缘计算、资源优化等。



姜春晓：清华大学北京信息科学与技术国家研究中心副研究员，主要研究方向为卫星通信、空天地一体化网络、博弈论、机器学习、边缘计算、资源优化等。



王佳蔚：清华大学北京信息科学与技术国家研究中心博士后，主要研究方向为卫星通信、信号处理、资源优化等。



孙佳辰：清华大学电子工程系在读博士研究生，主要研究方向为天基算力网络、人工智能赋能空间网络、边缘计算、资源优化等。



詹亚锋：清华大学北京信息科学与技术国家研究中心研究员，主要研究方向为卫星测控系统、通信信号处理、深空通信等。