

基于多智能体强化学习的车臂协同控制方法*

陈晋生,徐友春,李子先,王 乐,夏子雯
(中国人民解放军联勤保障部队工程大学,天津 300161)

[摘要] 现有的许多方法对单个机器人使用单智能体强化学习,或对多机器人系统中的协作任务使用多智能体强化学习。与现有方法不同,为提高无人车与其机械臂载荷模块之间的协调控制性能,提出一种基于多智能体强化学习的车臂协同控制方法。首先,根据轮式移动机械臂结构特点,训练多个智能体控制轮式移动机器人的不同部分,以解耦的方式同时最大化全局和局部奖励,实现轮式移动机械臂在完成全局任务的同时,提高机械臂的可操作性;其次,基于 Isaac Sim 平台构建训练仿真环境,针对两种不同任务场景进行训练;最后,通过设计系统部署框架,将模拟训练后的控制策略从 Isaac Sim 部署到 Gazebo 环境和实车环境。仿真及实验结果表明,基于解耦多智能体深度确定性策略梯度(DE-MADDPG)的控制方法在收敛速度、成功率和可操作性方面优于基线方法 DDPG 和 MADDPG,能够有效优化机械臂构型,提高车臂协同控制性能。

关键词: 无人车;机械臂;多智能体强化学习;协同控制;可操作性

Multi-Agent Reinforcement Learning-Based Cooperative Control for Vehicle-Manipulator Systems

Chen Jinsheng, Xu Youchun, Li Zixian, Wang Le & Xia Ziwen

PLA Joint Logistics Support Force University of Engineering, Tianjin 300161

[Abstract] Many existing methods employ single-agent reinforcement learning (SARL) for individual robot or multi-agent reinforcement learning (MARL) for cooperative tasks in multi-robot systems. Unlike these approaches, to enhance the coordination control performance between an unmanned ground vehicle and its manipulator payload module, a vehicle-manipulator coordination control method based on MARL is proposed. Firstly, according to the structural characteristics of wheeled mobile robots, multiple agents are trained to control different components of the wheeled mobile manipulator. By maximizing global and local rewards simultaneously in a decoupled manner, the method enables the wheeled mobile manipulator to complete global tasks while improving the manipulator's manipulability. Secondly, the training simulation environment is constructed based on the Isaac Sim platform, and training is conducted for two different task scenarios. Finally, through designing a system deployment framework, the control policies obtained from simulation training are deployed from Isaac Sim to both the Gazebo environment and real vehicle environment. The simulation and experimental results show that the control method based on DE-MADDPG outperforms the baseline methods DDPG and MADDPG in terms of convergence speed, success rate, and manipulability, which can effectively optimize the manipulator configuration and enhance the vehicle-manipulator coordination control performance.

Keywords: unmanned ground vehicles; manipulator; MARL; coordinated control; manipulability

* 军队重点科研项目(LJ20232B030153)资助。

原稿收到日期为 2025 年 06 月 17 日,修改稿收到日期为 2025 年 07 月 29 日。

通信作者:李子先,讲师,博士,E-mail:llizixian@163.com。

前言

随着无人车应用场景日益多样化,为其加装机械臂载荷的需求显著增长,同时也对车臂协同控制性能提出了更高要求。为无人车加装机械臂载荷后的轮式移动机械臂兼具轮式移动平台卓越的移动性能和多自由度机械臂灵巧作业性能,更便于应对各种复杂场景中的自主作业任务需求^[1]。与传统的固定基座机械臂相比,将机械臂安装在轮式移动平台上解决了机械臂工作空间的限制,可以具有更大的作业范围,增强了机械臂末端的灵活性;相较于传统的无人地面车辆(unmanned ground vehicle, UGV),移动机器人通过加装机械臂增强了其地形通过能力、系统稳定性以及自主作业能力^[2-3],实现从单纯的运输工具升级为具备多任务执行能力的移动机器人。目前,轮式移动机器人已经在家庭服务、工厂智能制造、医疗辅助精、危险环境特种作业以及军事作战后勤支援等场景中展现出不可替代的应用价值与巨大的发展潜力^[4]。

轮式移动平台与机械臂的结合虽然优势明显,但也带来了新的挑战。一是两个系统的结合增加了运动学冗余性,系统建模难度大大增加;二是两个系统具有不同的运动特性,在系统结构设计和运动控制方面面临新的问题;三是轮式移动平台通常要处理非完整约束,相较于机械臂运动精度低,动态响应慢。针对这些问题,早期的研究主要围绕传统控制方法展开,文献[5]中通过组合运动学、动态和滑模控制设计移动机器人控制器来改进控制策略,解决了车轮打滑补偿问题;文献[6]中提出了一种基于采样的移动机器人模型预测控制方法,通过优化目标函数实现了移动机器人的控制器设计;文献[7]中提出了一种基于零空间探索的移动机器人自适应多目标控制框架,提高了移动机器人的运动精度。传统控制方法已广泛应用于移动机器人的控制器设计,但其高度依赖于运动学方程的求解或者目标函数的优化。在面对结构复杂、高维度的机器人模型时,不仅计算成本高昂,而且未充分考虑系统的耦合性,极大地制约了其在执行复杂任务时的效率与作业精度,难以满足现代工业与军事应用需求。

近年来,随着人工智能技术的发展,基于强化学习的控制策略^[8]为移动机器人的控制器设计提供了

新的解决方案,主要是基于单智能体强化学习(single-agent reinforcement learning, SARL)设计集中控制器和基于多智能体强化学习(multi-agent reinforcement learning, MARL)设计分散式控制器。目前,很多研究已经证明了SARL方法在移动机器人控制方面的有效性,如:利用移动机器人完成开关门操作^[9-10]、自适应技能学习室内抓取操作^[11],考虑工人安全的移动机器人避碰学习^[12]、目标识别跟踪操作任务^[13]、未知环境导航操作^[14]、可达性为先验控制^[15]、学习运动学可行性^[16]和经典的轨迹跟踪任务^[17]等。然而,相较于SARL集中控制架构,MARL方法凭借其独特的分散控制架构,赋予系统更加灵活、高效的控制策略,在机器人协同作业等复杂控制任务中取得显著成效^[18]。

然而,现有研究大多将单个轮式移动机械臂的车臂协同控制问题视为单一智能体的优化问题^[9-11],并采用SARL进行集中控制。这种方法虽然在某些任务中表现出一定的有效性,但在面对复杂的车臂协同任务时,难以充分发挥各部件的自主性和灵活性。具体而言,车体(运动学模型为SE(2))和机械臂(运动学模型为SE(3))的运动学特性差异显著,直接建模为单智能体会增加系统复杂度,难以有效处理运动学耦合问题。此外,车体负责导航和定位,而机械臂负责末端执行器操作,任务目标不同,将整个系统建模为单智能体会导致全局和局部奖励之间的平衡难以实现,容易产生次优解。现有的MARL算法在处理双奖励问题时,通常将局部和全局奖励信号组合成一个纠缠的多目标奖励函数,导致训练过程中的振荡和次优解^[19]。

受文献[20]和文献[21]启发,本文针对上述车臂协同控制问题,提出一种基于DE-MADDPG算法的解决方案。该方案将轮式移动平台与机械臂视为独立智能体,并构建包含1个全局评论网络和2个局部评论网络(分别对应两个智能体)的架构。通过设计局部奖励(分别优化机械臂的可操作性与移动平台的可达性)与全局奖励(驱动夹爪运动至目标抓取位姿),同时最大化局部与全局目标。该策略简化了问题复杂度,充分发挥了部件的自主性与灵活性,提升了系统整体性能。同时,通过避免奖励函数耦合,增强了学习的稳定性与效率。最后,本文将基于DE-MADDPG的MARL框架应用于单个轮式移动机械臂系统,实现了高效的车臂协同控制。本文主要工作如下:

(1) 提出一种面向单轮式移动机械臂的多智能体强化学习协同控制架构。将轮式移动机械臂的车臂协同控制问题建模为多智能体协作任务,并通过基于DE-MADDPG的MARL框架进行求解,实现了高效的车臂协同控制。

(2) 构建基于Isaac Sim的物理仿真训练环境及实车部署框架,解决了算法训练和实车迁移部署的问题。

(3) 实验结果表明,所提出的车臂协同控制方法提升了移动抓取任务的成功率与机械臂的可操作性,增强了轮式移动机器人的运动能力。

1 问题描述与建模

1.1 问题描述

如图1所示,本文旨在使轮式移动机器人能够像人类一样在完成抓取物体任务的同时优化“脚的站立位置”和“手臂的姿态”。典型移动抓取任务要求机器人末端夹爪到达目标点完成移动抓取,其关键在于在SE(2)空间中确定合适的机器人基座位置,以确保机械臂能够在SE(3)空间中触及目标点并维持良好的可操作性。该场景构成MARL中的典型协作任务。为此,本文将车臂协同控制问题建模为多智能体强化学习协同问题,基于DE-MADDPG算法训练车臂协同控制策略,实现轮式移动机器人的高效车臂协同控制。

1.2 无人车可达性区域建模

相较于逆运动学可达性映射(IRM)^[22]以及MoMa-Pos框架^[23]等复杂方法,本文方法是让轮式移动机械臂导航到机械臂工作空间范围。可达性区域是轮式移动机器人完成目标抓取任务时的UGV质心的合理位置区域,如图2所示。以机械臂基座的第1个关节为推荐工作空间的中心轴, d_m 是机械臂的工作空间半径, z_t 为抓取目标的 z 坐标, z_b 是机械臂第1关节的 z 坐标。从抓取目标出发垂直于地面的直线与从目标到机械臂第1关节延伸的直线之间的夹角为

$$\theta = \arccos\left(\frac{|z_t - z_b|}{d_m}\right) \quad (1)$$

$$r_{\text{reach}} = d_m \sin \theta + d_{bm} \quad (2)$$

式中: d_{bm} 为UGV质心到机械臂第1关节在 x 轴上的距离; r_{reach} 是可达性区域的半径。

由此可以根据目标点的位置求解出可达性区域大小,如图2所示。

1.3 机械臂可操作性指标

当机械臂的关节构型接近关节奇异点时,机械臂的可操作性降低,运动轨迹会发生异常,甚至可能导致关节速度无法控制,给硬件设备带来重大的损害。针对该问题,虽然已经有很多方法对此进行了研究^[25-26],但文献[27]中提出的可操作性指标仍然是被最广泛接受和使用的方法,其描述了机械臂达到任意速度的条件,且该指标是一个标量,在本文




图1 单轮式移动机械臂的多智能体强化学习控制




图2 轮式移动平台的可达性区域示意图

3.2节中利用该标量设计奖励函数,结合强化学习方法来解决轮式移动机器人的可操作性优化难题。

$$m(q) = \sqrt{\det(J(q)J(q)^T)} \in [0, \infty) \quad (3)$$

式中 $J(q)$ 是机械臂的雅可比矩阵。 $J(q)$ 的前3行表征末端执行器的平移速度能力,后3行对应旋转角速度能力。

2 多智能体强化学习算法

2.1 多智能体强化学习算法

本文将轮式移动机械臂的车臂协调控制问题建模为一个协作的多智能体强化学习问题,并将其描述为马尔可夫决策过程为基础的随机博弈框架,可以表示为式(4)的高维度元组。

$$G = (S, \{A_i\}, P, \{r_i\}, N, \gamma, T) \quad (4)$$

式中: S 表示状态空间; A_i 是第 i 个智能体的动作空间; P 为状态转移分布; r_i 表示第 i 个智能体的奖励函数; $\gamma \in [0, 1]$ 是折扣因子; N 是智能体的数量。在每个时间步 t , 每个智能体 $i \in \{\text{arm}, \text{ugv}\}$ 选择一个动作 $a_i^t \in A$, 产生一个联合动作 $a^t = [a_{\text{base}}^t, a_{\text{arm}}^t]$ 。环境根据状态转移概率 $P(s_{t+1}|s_t, a_t)$ 过渡到新状态 s_{t+1} , 并返回共享奖励 $r(s_t, a_t)$, 用于引导两个智能体的协同

优化。多智能体强化学习的目标是学习一组策略 $\{\pi^i\}_{i=1}^N$, 使得多智能体系统的联合策略期望累计奖励最大化:

$$J(\pi) = \mathbb{E} \left[\sum_{t=0}^T \gamma^t r(s_t, a_t) \right] \quad (5)$$

式中: $J(\pi)$ 指多智能体系统的联合策略期望累计奖励; $\gamma \in [0, 1]$ 是折扣因子; $r(s_t, a_t)$ 是在状态 s_t 下执行联合动作 a_t 后获得的即时奖励; $\mathbb{E}$ 表示数学期望, 用于计算在所有可能的状态和动作组合下, 累积奖励的平均值。

2.2 DE-MADDPG 算法

DE-MADDPG 算法是 MADDPG 的改进算法^[19], MADDPG^[28] 算法是通过全局的 Critic 网络实现集中训练, 而 DE-MADDPG 算法则改进了网络架构, 除了一个全局的 Critic 网络, 还同时为每个智能体构建了一个局部的 Critic 网络, 目的是能够同时以解耦的方式最大化全局奖励和局部奖励, 算法的主要思想是将 MADDPG 与 DDPG 结合起来同时最大化全局奖励和局部奖励。该算法是一个集中训练、分散执行的架构, 仅在训练阶段需要其他智能体的状态和动作信息, 应用执行时只需要智能体自身状态就可以输出策略动作, 这一特点可以增强系统鲁棒性。

在 N 个智能体的环境中, 策略 $\pi = \{\pi_1, \dots, \pi_N\}$ 被 $\theta = \{\theta_1, \dots, \theta_N\}$ 参数化。在 MADDPG 算法中, 智能体 i 的策略梯度如下:

$$\nabla J(\theta_i) = \mathbb{E} \left[\nabla_{\theta_i} \pi_i(a_i | o_i) \nabla_{a_i} Q_i^\pi(s, a_1, \dots, a_N) \right]_{a_i = \pi_i(o_i)} \quad (6)$$

式中: $s = \{o_1, \dots, o_N\}$ 为环境状态; $Q_i^\pi(s, a_1, \dots, a_N)$ 为利用状态 s 和所有智能体动作估计智能体 $i = \{\text{ugv}, \text{arm}\}$ 的状态动作 Q 值。

DE-MADDPG 引进了局部的 Critic 网络, 智能体 i 的策略梯度可以写为

$$\nabla J(\theta_i) = \overbrace{\mathbb{E}_{s, a \sim \mathcal{D}} \left[\nabla_{\theta_i} \pi_i(a_i | o_i) \nabla_{a_i} Q_\psi^g(s, a_1, \dots, a_N) \right]}^{\text{MADDPG}} + \mathbb{E}_{o_i, a_i \sim \mathcal{D}} \left[\nabla_{\theta_i} \pi_i(a_i | o_i) \nabla_{a_i} Q_i^\pi(o_i, a_i) \right] \text{DDPG} \quad (7)$$

式中: $a_i = \pi_i(o_i)$ 是 agent_i 遵循策略 π_i 的动作; $\mathcal{D}$ 是经验重放缓冲区; Q_ψ^g 为全局 Critic 网络评价的 Q 值; ψ 为所有智能体的联合策略。

全局 Critic 网络 Q_{ψ}^g 的损失函数为

$$L(\psi) = \mathbb{E}_{s,a,r,s'} \left[\left(Q_{\psi}^g(s, a_1, \dots, a_N) - y_g \right)^2 \right] \quad (8)$$

$$y_g = r_g + \gamma Q_{\psi}^g(s', a'_1, \dots, a'_N) \Big|_{a'_i = \pi'_i(o'_i)} \quad (9)$$

式中: y_g 为目标价值; r_g 为全局奖励; Q_{ψ}^g 为全局目标评价网络; $\pi' = \{\pi'_1, \dots, \pi'_N\}$ 是由网络参数 $\theta' = \{\theta'_1, \dots, \theta'_N\}$ 定义的策略目标。

局部 Critic 网络 Q_i^{π} 的损失函数如下:

$$L(\phi_i) = \mathbb{E}_{o,a,r,o'} \left[\left(Q_i^{\pi}(o_i, a_i) - y_i \right)^2 \right] \quad (10)$$

$$y_i = r_i^i + \gamma Q_{\phi_i}^{\pi'}(o'_i, a'_i) \Big|_{a'_i = \pi'_i(o'_i)} \quad (11)$$

式中: y_i 为局部目标价值; r_i^i 表示智能体 i 的局部奖励, $i \in \{\text{arm}, \text{ugv}\}$; γ 为折扣因子; $Q_{\phi_i}^{\pi'}$ 为智能体 i 的局部 Critic 网络; o'_i 为智能体 i 下一时刻观测; a'_i 为智能体 i 的目标策略动作; π'_i 为智能体 i 的目标策略网络。

3 车臂协同控制问题建模

移动机器人的协调控制问题是指控制机械臂和 UGV 协同控制完成目标抓取任务,同时兼顾 UGV 的可达性和机械臂的可操作性。所以存在移动机器人整体目标以及 UGV 和机械臂的个体目标,如图3所示,本文基于 DE-MADDPG 算法设计实现车臂协同控制策略框架。其中,全局奖励是末端夹爪到达目标点,局部奖励函数设计考虑基座的可达性和机械臂的可操作性。具体而言,将移动机器人划分为 UGV 和机械臂两部分,由两个智能体分别控制。根据移动机器人的结构特性,结合 DE-MADDPG 算法,为2个智能体设计独立的奖励函数,从而在考虑可达性和可操作性的情况下,协同完成目标点到达任务。




图3 基于DE-MADDPG的车臂协同控制网络结构

3.1 动作状态设计

如图3所示,将移动机器人划分为机械臂 $agent_{\text{arm}}$ 和轮式移动平台 $agent_{\text{ugv}}$ 两个智能体,分别实现车臂的控制以及协作。智能体的联合状态信息为 $(s_{\text{ugv}}, s_{\text{arm}}, s_{\text{ee}}, s_{\text{target}})$ 。其中, $agent_{\text{ugv}}$ 的状态 $s_{\text{ugv}} \in \mathbb{R}^3$ 是其相对于起始位置的XY平面内的位移和在全局框架中的偏航。 $agent_{\text{arm}}$ 的状态包括关节角度和角速度 $s_{\text{arm}} \in \mathbb{R}^{14}$, 机械臂末端夹爪的位置 $s_{\text{ee}} \in \mathbb{R}^3$, 目标位置 $s_{\text{target}} \in \mathbb{R}^3$, s_{ee} 和 s_{target} 的位置相对于基地的起始位置。

智能体的动作空间是 $agent_{\text{ugv}}$ 的线速度和角速度 (v, w) 和 $agent_{\text{arm}}$ 的关节角度 $a_{\text{arm}} \in \mathbb{R}^7$ 。所有的动作都是连续的,为了稳定训练和避免过拟合,动作和状态空间被归一化为 $[-1, 1]$ 。

机械臂动作空间由关节速度 $\dot{q} \in [-1, 1]^n$ 组成,

其中关节速度变化是连续的, n 是机械臂的关节个数。

$agent_{\text{base}}$ 动作 a_i 由两个连续值组成:线速度 $v \in [-1, 1]$ 和角速度 $w \in [-1, 1]$ 。假设机器人可以在全局地图中定位自己,以确定其相对于目标位置的相对位置。

3.2 奖励函数设计

设计合理的奖励机制对引导车臂系统实现全局与个体控制目标、探索高效车臂协同策略具有决定性作用。本文的奖励函数设计聚焦于轮式移动机器人两个核心任务目标:一是末端执行器精准到达目标点位;二是移动平台高效导航至可达操作区域并优化机械臂可操作性。为此,奖励函数通过激励期望行为与抑制不良行为来优化系统性能,其结构包含全局奖励函数与局部奖励函数两部分。

3.2.1 全局奖励函数

车臂协同控制全局奖励函数设计如下:

$$R_{\text{global}} = \underbrace{\alpha_1 \exp(-\beta_1 \|p_{\text{target}} - p_{\text{gripper}}\|^2)}_{\text{末端运动引导}} + \underbrace{\alpha_2 \exp(-\gamma \theta_e^2)}_{\text{车臂夹角约束}} - \underbrace{\lambda_1 \sum \mathbb{I}_{f_c} > 0.1}_{\text{碰撞安全}} \quad (12)$$

式中: p_{target} 和 p_{ee} 分别为目标点位置和末端夹爪当前位置; α_1 为末端引导奖励权重系数和 α_2 为车臂夹角奖励权重系数; θ_e 是车体与机械臂方向夹角(见图4); λ_1 为碰撞惩罚系数; 符号 $\mathbb{I}$ 为接触力超阈值指示函数($\|f_c\| > 0.1$ 时激活)。奖励项及权重系数的数值详见表1。




图4 车体方向与机械臂方向之间的夹角

3.2.2 局部奖励函数

基于机械臂运动学特性与操作需求,设计局部奖励函数 R_{arm} 以优化机械臂运动性能:

$$R_{\text{arm}} = \underbrace{\kappa_2 m(q)}_{\text{可操作性}} - \underbrace{\lambda_2 \sum \|\dot{q}\|^2 - \lambda_3 \sum \|\ddot{q}\|^2}_{\text{运动平稳性}} + \underbrace{\kappa_3 \|z_{\text{gripper}} \cdot [0, 0, -1]^T\|}_{\text{末端方向约束}} - \underbrace{\lambda_4 \sum \mathbb{I}_{\text{joint_limit}}}_{\text{关节极限惩罚}} \quad (13)$$

式中: κ_2 是可操作性奖励权重系数; $m(q)$ 为1.3节定义的可操作性指标,最大化 $m(q)$ 可避免奇异构型,提升运动灵活性; $\dot{q}$ 和 $\ddot{q}$ 分别为机械臂关节角速度与角加速度; λ_2 和 λ_3 分别为关节速度和加速度惩罚系数; κ_3 为末端方向奖励权重; z_{gripper} 是夹爪 z 轴方向向量; λ_4 为关节极限惩罚系数; $\mathbb{I}_{\text{joint_limit}}$ 为关节越限指示函数,防止关节超出物理运动范围。

基于UGV导航任务需求,设计局部奖励函数 R_{base} 以优化轮式移动平台性能:

$$R_{\text{base}} = \underbrace{\eta_1 (r_{\text{reach}} - \|p_{\text{base}} - p_{\text{target}}\|)}_{\text{可达性}} - \underbrace{\eta_v \|v_t - v_{t-1}\|^2 - \xi_\omega \|\omega\|^2 - \xi_\alpha \|\dot{\omega}\|^2}_{\text{轮式移动平台的运动平稳性}} - \underbrace{\xi_z \mathbb{I}_{\|v\| < 0.1} \|\omega\|}_{\text{零半径转向惩罚}} + \underbrace{\eta_m \|v\|}_{\text{移动效率}} \quad (14)$$

式中: η_1 为可达性奖励系数; $r_{\text{reach}} \in SE$ 为式(2)定义的机械臂可达性区域半径(目标点 p_{target} 为中心的圆形区域,见图2); η_v 和 ξ_ω 分别为轮式移动平台的线速度和角速度惩罚系数; v 和 w 分别为轮式移动平台的线速度和角速度; ξ_z 是零半径转向惩罚系数; $\mathbb{I}_{\|v\| < 0.1}$ 为零半径转向指示函数; η_m 为移动效率奖励系数。所有奖励项及权重系数的具体数值详见表1。

表1 奖励函数

类别	奖励项	奖惩函数	权重系数
全局奖励函数	末端夹爪运动引导奖励	$\alpha_1 \exp(-\beta_1 \ p_{\text{target}} - p_{\text{gripper}}\ ^2)$	$\alpha_1 = 5.0$ $\beta = 10.0$
	车臂方向夹角奖励	$\alpha_2 \exp(-\gamma \theta_e^2)$	$\alpha_2 = 2.0$ $\gamma = 5.0$
	碰撞惩罚	$-\lambda_1 \sum \mathbb{I}_{f_c} > 0.1$	$\lambda_1 = 1.0$
局部奖励函数	可操作性奖励	$\kappa_2 \cdot m(q)$	$\kappa_2 = 0.5$
	关节速度惩罚	$-\lambda_2 \sum \ \dot{q}\ ^2$	$\lambda_2 = 0.01$
	关节加速度惩罚	$-\lambda_3 \sum \ \ddot{q}\ ^2$	$\lambda_3 = 0.001$
	末端夹爪姿态奖励	$\kappa_3 \ z_{\text{gripper}} \cdot [0, 0, -1]^T\ $	$\kappa_3 = 0.1$
	关节极限惩罚	$-\lambda_4 \sum \mathbb{I}_{\text{joint_limit}}$	$\lambda_4 = 1.0$
	可达性区域奖励	$\eta_1 (r_{\text{reach}} - \ p_{\text{base}} - p_{\text{target}}\)$	$\eta_1 = 1.2$
	线速度平滑奖励	$-\eta_v \ v_t - v_{t-1}\ ^2$	$\eta_v = 0.03$
	角速度幅值惩罚	$-\xi_\omega \ \omega\ ^2$	$\xi_\omega = 0.03$
	角加速度惩罚	$-\xi_\alpha \ \dot{\omega}\ ^2$	$\xi_\alpha = 0.005$
	零半径转向惩罚	$-\xi_z \cdot \mathbb{I}_{\ v\ < 0.1} \cdot \ \omega\ $	$\xi_z = 0.1$
	移动效率奖励	$\eta_2 \ v\ $	$\eta_2 = 0.1$

3.3 车臂协同控制训练算法流程

车臂协同控制策略训练算法流程详见算法1, 训练过程中涉及的关键超参数及其含义如表2所示。

算法1 车臂协同控制训练算法

算法1 基于DE-MADDPG的车臂协同控制训练算法

```

1: 初始化全局 EvalCritic 网络  $Q_{\psi}^g$ 
2: 初始化全局 TargetCritic 网络  $Q_{\psi}^g$ , 并拷贝  $Q_{\psi}^g$  参数
3: 初始化  $agent_{ugv}$  和  $agent_{arm}$  的 TargetActor 网络  $Q_{\theta_{ugv}}^g, Q_{\theta_{arm}}^g$  和 Target-
   Critic 网络  $Q_{\psi_{ugv}}^g, Q_{\psi_{arm}}^g$ 
4: For episode = 1 to MaxEpisode do
5:   在设定范围内随即生成目标位置;
6:   设定移动机器人的初始状态;
7:   For  $t = 1$  to MaxStep do
8:     获得仿真环境初始状态  $s^t, a_{ugv}^t = \pi\theta_{ugv}(O_{ugv}^t), a_{arm}^t =$ 
        $\pi\theta_{arm}(O_{arm}^t)$ 
9:     执行联合动作  $a^t = [a_{ugv}^t, a_{arm}^t]$ 
10:    获得全局奖励  $r_{global}^t$  和局部奖励  $r_{ugv}^t, r_{arm}^t$ 
11:    存储样本  $(s^t, a^t, a_{ugv}^t, a_{arm}^t, r_{global}^t, s^{t+1})$  到经验池
12:  End For
13: /*全局 Critic 网络更新*/
14: 从经验池随机抽样  $S$  个样本组成小批量样本  $S(s^j, a^j, r_g^j, s'^j)$ 
15:  $(a_{ugv}^j, a_{arm}^j) = (\pi'\theta_{ugv}(O_{ugv}^j), \pi'\theta_{arm}(O_{arm}^j))$ 
16: 设置  $y_g^j = r_g^j + \gamma \min_{i=ugv, arm} Q_{\psi_i}^g(s^j, a_{ugv}^j, a_{arm}^j)$ 
17: 最小化损失  $\frac{1}{S} \sum_j (y_g^j - Q_{\psi}^g(s^j, a_{ugv}^j, a_{arm}^j))^2$ , 更新全局 EvalCritic
   网络  $Q_{\psi}^g$  参数
18: 更新全局 TargetCritic 网络  $Q_{\psi}^g$  参数  $\psi_i' \leftarrow \tau\psi_i + (1 - \tau)\psi_i'$ 
19: If episode mod  $d$  then
19: /*更新  $agent_{ugv}$  与  $agent_{arm}$  的 Actor 网络和局部 Critic 网络*/
20: For  $agent\ i = 1$  to  $N$  do
21: 从经验池随机抽样  $K$  个样本组成小批量样本  $S(s^j, a^j, r_i^j, s'^j)$ ,
   设置  $y^j = r_i^j + \gamma Q_{\theta_i'}^g(o^j, \pi_{\theta_i'}(o_i^j))$ 
22: 计算损失  $\frac{1}{S} \sum_j (y^j - Q_{\phi_i}^g(o^j, a_i^j))^2$ 
23: 更新 EvalActor 网络  $Q_{\theta_{ugv}}^g, Q_{\theta_{arm}}^g$  的网络参数  $\theta_i = \theta_i +$ 
    $\frac{1}{S} \sum_j \nabla_{\theta_i} \pi_i(a_i | o_i^j) \nabla_{a_i} Q_{\psi_i}^g(s^j, a_{ugv}^j, a_{arm}^j) +$ 
    $\nabla_{\theta_i} \pi_i(a_i | o_i^j) \nabla_{a_i} Q_{\phi_i}^g(o^j, a_i^j)$ 
24: 软更新方式刷新  $agent_i$  Actor 网络  $Q_{\theta_{ugv}}^g, Q_{\theta_{arm}}^g$  和 Critic 网络
    $Q_{\psi_{ugv}}^g, Q_{\psi_{arm}}^g$ 
25: End For
26: 更新  $agent_{ugv}$  和  $agent_{arm}$  目标网络参数  $\theta'$  和  $\phi'$ 
27:  $\theta_i' \leftarrow \tau\theta_i + (1 - \tau)\theta_i', \phi_i' \leftarrow \tau\phi_i + (1 - \tau)\phi_i'$ 
28: End If
29: End For

```

表2 训练算法参数

训练参数	数值
折扣因子 γ	0.89
回放经验池大小 M	30 000
惯性更新率 τ	0.01
仿真时间步长 ΔT	0.1
训练回合数 MaxEpisode	500
单回合最大时间步 MaxStep	8 000
Critic 网络学习率 α_Q	0.003
Actor 网络学习率 α_{μ}	0.001

4 仿真训练

4.1 任务场景设置

针对轮式移动机器人的车臂协调控制问题, 设计典型的移动抓取任务, 验证所提出控制方法的有效性。如图5所示, 左图为无障碍物简单环境, 右图为多障碍物复杂环境。在复杂场景中, 置物平台、球体和正方体障碍物使场景避障和运动规划更具挑战性。这些障碍物的形状和分布要求机械臂路径规划须兼顾障碍物几何特性与自身运动学特性, 以保障安全高效作业。而在简单场景中, 到达任务主要关注机械臂自身碰撞问题, 外部环境影响较小, 实现难度较低。具体实验环境参数见表3。通过对比 DE-MADDPG、DDPG 以及 MADDPG 这3种控制策略在2种实验场景中的表现来评估3种控制策略的性能。

表3 实验环境参数

实验参数	数值
Frank panda 初始姿态	$[0, -3, 0, -2.3, 0, 2, 0]$
机械臂推荐工作空间半径 d_m	655 mm
随即目标点生成空间范围	长 5 m, 宽 5 m, 高 1.5 m
固定目标点 1	(0.3, 2.0, 0.7) m
固定目标点 2	(-2.0, -1.0, 0.4) m
方块障碍物尺寸	长、宽、高均为 0.89 m
球体障碍物尺寸	半径 0.5 m
长方体台子尺寸	长 3 m, 宽 0.6 m, 高 1.2 m




图5 任务场景

4.2 仿真训练

基于 NVIDIA Isaac Sim 搭建物理仿真训练环境,模拟运行频率设为 120 Hz,强化学习算法的交互频率设定为 60 Hz。抓取目标位置在预设范围内随机生成。机器人的观测与动作按第3节所述建模。Isaac Sim 提供构建观测与奖励所需的全部信息,包括机器人姿态、关节位置与速度,并据此计算观测张量和奖励值。这些信息被传递给各强化学习算法以训练控制策略;生成的动作指令随后发送至 Isaac Sim 的内置控制器,设定机械臂关节速度以及轮式平台的平移和旋转速度,实现移动机械臂的协调控制。训练过程如图6所示。




图6 NVIDIA Isaac Sim 512个并行环境训练过程

4.3 结果分析

在仿真过程中,为了监测训练进展,使用训练跟踪与可视化工具 SwanLab 平台记录和分析训练结果。2种任务场景中的训练结果如图7所示。实验结果为每个环境配置进行5次重复训练的平均奖励值。通过这种方式,可以有效地比较3种控制策略的表现。

根据训练数据分析可以看出,两个任务中的多个训练过程对3种策略都显示出一致的学习曲线。总体而言,与基线方法 DDPG 和 MADDPG 相比,基于 DE-MADDPG 的学习曲线(红色)具有最高的学习速度和收敛成功率,尤其是在复杂任务场景中,由于机械臂可操作度的优化,使得移动机械臂在目标点到达任务中仍然保持较高的成功率和较快的收敛速度。训练结果表明多智能体强化学习控制策略在单个复杂机器人运动控制中的有效性。

4.4 随机目标点到达测试

为评估3种控制策略的性能,对于每个目标点到达任务,采用可达性和可操作性两个核心指标进行性能评估。可达性指末端夹爪在设定误差范围内成功到达目标点的成功率,反映末端执行器的精度和可靠性。可操作性则从两个维度评估:①整个任务轨迹中机械臂可操作性的均值,反映机械臂在整个任务过程中的平均可操作性水平,是体现其整体性能的综合指标;②最终可操作性,反映机械臂在任




图7 不同任务场景的平均奖励曲线

务结束时的可操作性,可评估其任务结束时是否处于良好操作状态,例如能否快速切换到下一个任务或应对突发情况,是对任务完成后运动能力的直接评估。

性能评估使用一个固定的 100 个随机目标位置构成的测试集,并对该测试集进行 50 轮完整仿真,共产生 5 000 条轨迹,结果取均值后列于表4和表5。在评估过程中,所提出的基于 DE-MADDPG 的控制策略在两种任务设置下都达到了最佳性能。任务1中,DE-MADDPG 不仅实现了最高的成功率,其平均可操作性和平均最终可操作性也分别达到了 0.090 2 和 0.092 4,优于其他两种策略;任务2中,尽管所有策略的成功率都有所下降,但 DE-MADDPG 依然表现出色,成功率达到 98.6%,且平均可操作性和平均最终可操作性分别为 0.087 2 和 0.091 1,高于 DDPG 和 MADDPG。

表4 任务1仿真环境下成功率和可操作性评估

方法	平均可操作性	平均最终可操作性	成功率/%
DDPG	0.051 3±0.011 6	0.052 8±0.019 7	100
MADDPG	0.088 0±0.003 96	0.081 0±0.029 6	79.6
DE-MADDPG	0.090 2±0.005 93	0.092 4±0.016 1	100

表5 任务2仿真环境下成功率和可操作性评估

方法	平均可操作性	平均最终可操作性	成功率/%
DDPG	0.030 1±0.012 6	0.032 8±0.021 6	89.2
MADDPG	0.058 0±0.004 76	0.045 1±0.013 9	31.2
DE-MADDPG	0.087 2±0.001 83	0.091 1±0.023 2	98.6

5 实验

5.1 实验平台

现场实验平台如图8所示。软件方面,基于ROS搭建控制系统,Rviz主要用于移动机器人控制和数据显示,Matlab用于坐标转换和运动学验证计算,VScode用于代码调试,NVIDIA Isaac Sim用于构建物理仿真环境及强化学习训练。在算法实现环节,本文选用了RLGames库提供的DDPG算法以及MADDPG算法,并构建DE-MADDPG算法来实现不同的控制策略。



图8 轮式移动机器人软硬件结构

硬件方面,将协作式7自由度机械臂 Frank Panda集成到自研轮式地面移动平台上,构成轮式移动机器人系统,其软硬件构成和周边设备构成如图8所示。其中,UGV为六轮差速转向,前后安装Velodyne VLP-16激光雷达与IMU(T1-901)模块用于获取移动平台的实时位姿,UGV的控制器运行在车载域控制器中,机械臂的控制器运行在配置为Intel Core i7-9700K,8核32 GB的便携式计算机中,机械臂末端执行机构为DH(PGI-140-80)工业型平行电动夹爪。

5.2 仿真到实车部署框架

如图9所示,模拟到仿真的部署框架以ROS节点为核心,使用从Isaac Gym导出的ONNX格式神经网络控制机器人。为确保模拟训练策略能够直接应用于真实机器人,本研究采用在Gazebo中测试验证,随后部署到真实环境的模式。Isaac Sim仿真环境中的坐标框架与Gazebo和真实环境相匹配,状态和动作空间与训练环境保持一致。




图9 从Isaac Sim到Gazebo及真实环境的部署框架

在ROS节点中,使用TF变换监听器来获得基座和末端执行器的姿势,手臂的观测值(即关节位置和速度)从franka_control节点发布的主题中读取。所有姿势和手臂的观测值都以与训练阶段相同的方式进行缩放,然后适当地组合成神经网络的输入。智能体指标以与训练相同的方式添加到输入中。然后将智能体观测结果传递给神经网络以获得动作。控制回路以与模拟器中相同的60 Hz频率运行。

5.3 Gazebo环境随机目标点实验

在实际实验部署之前,先在Gazebo中进行部署测试,这种模式有利于实车部署的安全性和效率。首先对照Isaac Sim训练环境在Gazebo中搭建任务场景,根据5.2节设计部署框架,将训练模型权重文件导入到ROS环境中,在Gazebo中实现随机目标点到达任务测试。对两种任务场景分别进行了10次目标点在指定区域随机生成的到达任务实验。测试过程如图10所示。

表6和表7展示了在Gazebo环境下对两种不同任务场景进行的10次随即目标点实验测试的结果,包括平均可操作性、平均最终可操作性以及成功率。




图10 Gazebo环境随即目标点测试

在场景1中,基于DE-MADDPG的控制策略的成功率达到98.2%,其平均可操作性及平均最终可操作性均优于DDPG以及MADDPG。在场景2中,基于DE-MADDPG的控制策略成功率达到96.8%,平均可操作性为0.079 8,平均最终可操作性为0.080 1,相较于DDPG在平均可操作性上提高了约15.5%(从0.031 9提升至0.079 8),相较于MADDPG提升了约27.2%(从0.039 3提升至0.079 8)。测试结果表明,所提出的DE-MADDPG控制策略能够在保证高成功率的同时优化机械臂的构型,证明了基于DE-MADDPG的控制策略的有效性和鲁棒性。

表6 任务1 Gazebo环境下成功率和可操作性评估

方法	平均可操作性	平均最终可操作性	成功率/%
DDPG	0.050 5±0.009 66	0.050 1±0.016 5	96.8
MADDPG	0.063 6±0.005 14	0.060 1±0.015 3	77.6
DE-MADDPG	0.089 9±0.001 73	0.090 4±0.017 7	98.2

表7 任务2 Gazebo环境下成功率和可操作性评估

方法	平均可操作性	平均最终可操作性	成功率/%
DDPG	0.031 9±0.022 7	0.033 0±0.015 9	81.3
MADDPG	0.039 3±0.009 35	0.042 8±0.043 1	69.6
DE-MADDPG	0.079 8±0.009 91	0.080 1±0.012 7	96.8

5.4 固定目标点实车实验

根据5.2节的部署策略,将模型权重文件导入到ROS Noetic环境中,根据ROS节点和话题来控制移动机器人并读取其状态。为了更好地对比实验结果,为不同的场景设置2个相同的目标点进行定量分析,两个目标点分别为(0.3,2.0,0.7)、(-2.0,

-1.0,0.4)。所设置的目标点分别在移动机器人的左前和右后方,这样选择的目标点使得移动机器人必须做向前、向后和旋转运动,能够更好地测试不同控制策略的性能指标。

两组实验分别为两种任务场景中不同控制策略的目标点距离误差和可操作性变化。实验结果如图11所示,图中曲线分别为固定目标的距离误差和可操作性曲线,其中红色叉号代表未能到达目标点,图11(a)为任务场景1运行效果图,图11(b)为任务场景2运行效果图。在已知目标情况下,根据图中的距离误差曲线和可操作性曲线分析可知:在场景1中,3种控制策略均能完成任务目标,其中,DE-MADDPG和DDPG两种控制策略的控制效果要明显好于MADDPG。根据可操作性曲线可知,DE-MADDPG相较于DDPG和MADDPG控制策略,最终可操作性分别提高0.014和0.01,对比整个操作性曲线可知,DE-MADDPG对机械臂的可操作性优化效果明显。在场景2中,随着场景复杂度的增加,基于MADDPG的控制策略未能完成目标点到达任务。原因在于整个运动规划过程中,由于涉及障碍物避让,机械臂处于关节奇异位姿且未能及时调整导致发生碰撞的情况,降低了任务成功率。然而,基于DE-MADDPG的控制策略通过实时优化机械臂构型,显著提升了任务成功率和可操作性。在同样的复杂环境中,DE-MADDPG表现出更好的任务成功率,证明了本文所提出的控制策略的有效性和鲁棒性。

综上所述,由两组实验结果对比可知,基于DE-MADDPG的控制策略在两个环境中均有较高的控制效率,能够优化机械臂的可操作性,对不同任务场景具有较好的适应性。

5.5 锥形桶移动抓取实验

为评估控制策略在真实环境中的泛化能力,在实际场地进行了20次不同位置锥形桶的移动抓取实验。实验严格遵循5.2节的部署框架,使用与Gazebo仿真测试相同的模型权重。轮式移动机械臂利用手眼相机获取锥形桶的6D精确位姿,并应用DDPG、MADDPG和DE-MADDPG 3种控制策略执行任务。实验场景如图12所示,关键性能指标如表8所示。

实验结果与5.3节Gazebo仿真数据高度一致,验证了仿真训练和部署框架的有效性。在成功率方面,DE-MADDPG在20次实验中达成100%抓取成




图11 不同控制策略的目标点距离误差和可操作度变化曲线



图12 锥形桶移动抓取实验场景

表8 锥形桶移动抓取实车实验成功率和可操作性评估

方法	平均可操作性	平均最终可操作性	成功率/%
DDPG	0.048 2±0.006 8	0.049 8±0.008 2	95.0
MADDPG	0.040 3±0.009 7	0.041 9±0.008 9	75.0
DE-MADDPG	0.083 1±0.004 9	0.085 2±0.003 8	100.0

功率,高于DDPG(95.0%)和MADDPG(75.0%);在可操作性方面,DE-MADDPG的平均可操作度(0.083 1)较DDPG提升72.4%,较MADDPG提升106.2%;最终可操作度(0.085 2)同样高于基线方法。综上,基于DE-MADDPG的车臂协同控制方法在可操作性优化与任务成功率方面均超越基线方法。

6 结论

本文提出一种基于多智能体强化学习的单轮式移动机器人车臂协同控制方法。该方法在保障移动抓取任务成功率的同时,通过优化机械臂可操作性提升任务执行能力。首先,根据轮式移动机器人的结构特点以及任务目标,将其移动抓取问题建模为一个协作式的多智能体强化学习问题,并基于DE-MADDPG算法训练车臂协同控制策略;其次根据所设计的仿真到实车部署框架,实现从Isaac Sim仿真环境到实车的迁移;最后分别在Gazebo和真实环境中进行了目标点到达和锥形桶移动抓取任务测试。

实验结果表明,基于DE-MADDPG的控制策略在不同任务场景中,相较于DDPG和MADDPG方法,展现出更快的收敛速度和更高的成功率。在Gazebo仿真环境随即目标点到达实验中,所提出的控制策略与DDPG相比,可操作性提高了15.5%,相较于MADDPG,提高了27.2%。在真实环境固定目标点

和锥形桶移动抓取实验中,基于DE-MADDPG的控制策略相较于基线方法均有较高的成功率和可操作性,表明本文控制方法能够有效优化机械臂构型,提升操作性能。

下一步,在本文研究的基础上,将重点研究在移动机器人状态信息部分可观察的情况下,基于多智能体强化学习的车臂协同控制方法的鲁棒性,并探索其在应对关节故障以及复杂环境中的应用前景。

参考文献

- [1] 孙振平. 无人作战系统[M]. 长沙: 国防科技大学出版社, 2023: 79-85.
- [2] SUN Z P. Unmanned combat systems[M]. Changsha: National University of Defense Technology Press, 2023: 79-85.
- [3] 兰沅卜, 赵文博, 朱凯, 等. 基于具身智能的移动操作机器人系统发展研究[J]. 中国工程科学, 2024, 26(1): 139-148.
- [4] LAN F B, ZHAO W B, ZHU K, et al. Development of mobile manipulator robot systems based on embodied intelligence[J]. Strategic Study of CAE, 2024, 26(1): 139-148.
- [5] 关海杰, 王博洋, 王旭睿, 等. 搭载任务载荷军用地面无人系统发展综述[J]. 兵工学报, 2023, 44(11): 3333-3344.
- [6] GUAN H J, WANG B Y, WANG X R, et al. A review on the development of military unmanned ground system with mission payload[J]. Acta Armamentarii, 2023, 44(11): 3333-3344.
- [7] THAKAR S, SRINIVASAN S, SARAH B. A survey of wheeled mobile manipulation: a decision-making perspective[J]. Mechanisms Robotics, 2023, 15(2): 020801.
- [8] KORAYEM M H, DEHKORDI S F, GHOBADI N. Wheel slip-page compensation in mobile manipulators through combined kinematic, dynamic, and sliding mode control[J]. Arabian Journal for Science and Engineering, 2024, 49: 11565-11585.
- [9] CORRADO P, CHADI S, ELIA T, et al. Sampling-based model predictive control leveraging parallelizable physics simulations[J]. IEEE Robotics and Automation Letters, 2025, 10(3): 2750-2757.
- [10] XING H, GONG Z, DING L, et al. An adaptive multi-objective motion distribution framework for wheeled mobile manipulators via null-space exploration[J]. Mechatronics, 2023, 90: 102949.
- [11] 曹子建, 孙泽龙, 闫国闯, 等. 基于强化学习的无人机集群对抗策略推演仿真[J]. 兵工学报, 2023, 44(S2): 126-134.
- [12] CAO Z J, SUN Z L, YAN G C, et al. Simulation of reinforcement learning-based UAV swarm adversarial strategy deduction[J]. Acta Armamentarii, 2023, 44(S2): 126-134.
- [13] KAND G, SEONG H, LEE D. A versatile door opening system with mobile manipulator through adaptive position-force control and reinforcement learning[J]. Robotics and Autonomous Systems, 2024, 180: 104760.
- [14] ITO H, YAMAMOTO K, MORI H. Efficient multitask learning with an embodied predictive model for door opening and entry with whole-body control[J]. Science Robotics, 2022, 7(65):

- 8177-8183.
- [11] YOKOYAMA N, CLEGG A, UNDERSANDER E. ASC: adaptive skill coordination for robotic mobile manipulation[J]. IEEE Robotics and Automation Letters, 2024, 9(1): 779-786.
- [12] LIM J, LEE J, LEE C J. Designing path of collision avoidance for mobile manipulator in worker safety monitoring system using reinforcement learning[C]. Proceedings of the 2021 International Conference on Intelligence and Safety for Robotics (ISR). Tokoname, Japan: IEEE, 2021: 94-97.
- [13] KIM M, YANG S, KANG S, et al. Implementation of reinforcement learning environment for mobile manipulator using robo-gym[C]. Proceedings of the 2022 6th IEEE International Conference on Robotic Computing (IRC). L'Aquila, Italy: IEEE, 2022: 292-295.
- [14] HONERKAMP D, WELSCHHOLD T, VALADA A. N2M2: learning navigation for arbitrary mobile manipulation motions in unseen and dynamic environments[J]. IEEE Transactions on Robotics, 2023, 39(5): 3601-3619.
- [15] JAUHRI S, PETERS J, CHALVATZAKI G. Robot learning of mobile manipulation with reachability behavior priors[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 8399-8406.
- [16] HONERKAMP D, WELSCHHOLD T. Learning kinematic feasibility for mobile manipulation through deep reinforcement learning[J]. IEEE Robotics and Automation Letters, 2021, 6(4): 6289-6296.
- [17] ZHANG P, ZHANG J, KAN J. A research on manipulator-path tracking based on deep reinforcement learning[J]. Applied Sciences, 2023, 13(13): 7867.
- [18] 符小卫, 王辉, 徐哲. 基于DE-MADDPG的多无人机协同追捕策略[J]. 航空学报, 2022, 43(5): 325311-325317.
- FU X W, WANG H, XU Z. Cooperative pursuit strategy for multi-UAVs based on DE-MADDPG algorithm[J]. Acta Aeronauticae Astronautica Sinica, 2022, 43(5): 325311-325317.
- [19] SHEIKH H U, BOLONI L. Multi-agent reinforcement learning for problems with combined individual and team reward[C]. Proceedings of the 2020 International Joint Conference on Neural Networks (IJCNN). Glasgow, UK: IEEE, 2020: 1-8.
- [20] TAO L F, ZHANG J C, BOWMAN M, et al. A multi-agent approach for adaptive finger cooperation in learning-based in-hand manipulation[C]. Proceedings of the 2023 International Conference on Robotics and Automation (ICRA). London, United Kingdom: IEEE, 2023: 3897-3903.
- [21] ZHAO W S, ALEKSI E R, PAJARINEN J. Less is more: robust robot learning via partially observable multi-agent reinforcement learning: arXiv: 2309.14792 [R/OL]. Ithaca, NY, US: Cornell University, 2023 (2023-09-26). <https://arxiv.org/abs/2309.14792>.
- [22] MAKHAL A, GOINS A K. Reuleaux: robot base placement by reachability analysis[J]. Computer Society, 2018: 137-142.
- [23] SHAO B C, CAO N Q, DING Y, et al. MoMa-Pos: where should mobile manipulators stand in cluttered environment before task execution: arXiv: 2403.19940 [R/OL]. Ithaca, NY, US: Cornell University, 2024 (2024-05-29). <https://arxiv.org/abs/2403.19940>.
- [24] ZHOU Z X, YANG X Y, WANG H, et al. Coupled dynamic modeling and experimental validation of a collaborative industrial mobile manipulator with human-robot interaction[J]. Mechanism and Machine Theory, 2022, 176: 105025.
- [25] AKLI I. Trajectory planning for mobile manipulators including manipulability percentage index[J]. International Journal of Intelligent Robotics and Applications, 2021, 5: 543-557.
- [26] CHOI Y S, RHEE I, HOANG P T. Simple desired manipulability ellipsoid with velocity and force for control of redundant manipulator[J]. Journal of Mechanical Science and Technology, 2023, 37: 2033-2041.
- [27] YOSHIKAWA T. Manipulability of robotic mechanisms[J]. The International Journal of Robotics Research, 1985, 4(2): 3-9.
- [28] WU L S, QU J S, LI S L, et al. Attention-augmented MADDPG in NOMA-based vehicular mobile edge computational offloading[J]. IEEE Internet of Things Journal, 2024, 11(16): 27000-27014.