



南方电网技术
Southern Power System Technology
ISSN 1674-0629,CN 44-1643/TK

《南方电网技术》网络首发论文

题目：基于异构多智能体深度强化学习的钢铁工业多能耦合系统优化调度
作者：胡泉，贾金国，徐宪东，杨家全，梁俊宇，王世立
收稿日期：2025-11-30
网络首发日期：2026-04-08
引用格式：胡泉，贾金国，徐宪东，杨家全，梁俊宇，王世立. 基于异构多智能体深度强化学习的钢铁工业多能耦合系统优化调度[J/OL]. 南方电网技术.
<https://link.cnki.net/urlid/44.1643.TK.20260408.1047.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于异构多智能体深度强化学习的钢铁工业多能耦合系统优化调度

胡泉¹, 贾金国¹, 徐宪东², 杨家全³, 梁俊宇³, 王世立⁴

(东北电力大学电气工程学院, 吉林吉林 132012; 2. 天津大学电气自动化与信息工程学院, 天津 300072;
3. 云南电网有限责任公司电力科学研究院, 云南昆明 650217; 4. 云南曲靖呈钢钢铁(集团)有限公司, 云南曲靖 655100)

摘要: 针对钢铁工业中煤气-蒸汽-电力耦合系统在多能流协同优化与调度过程中存在的高度复杂性, 提出了一种基于多智能体深度强化学习 (Multi-Agent Deep Reinforcement Learning, MADRL) 的优化决策框架。以钢铁行业中的煤气、蒸汽与电力系统为对象, 将多目标优化任务建模为马尔可夫决策过程 (Markov Decision Process, MDP), 构建了融合动态设备特性与分时电价机制的系统模型, 旨在实现煤气与蒸汽资源的高效分配, 并提升余热发电的经济性。在方法设计上, 提出异构多智能体架构, 融合深度确定性策略梯度算法 (Deep Deterministic Policy Gradient, DDPG) 与深度 Q 网络算法 (Deep Q-Network, DQN) 两类智能体, 分别应对连续控制 (如流量调节) 与离散控制 (如设备启停) 问题。针对连续动作智能体, 引入基于长短期记忆网络 (Long Short-Term Memory, LSTM) 的 Actor-Critic 结构, 以更好地捕捉系统在多时间尺度下的动态变化和历史依赖性。通过协同优化煤气柜缓冲调节、蒸汽管网压力平衡与余热发电调度, 该模型在分时电价机制下显著提升了系统的经济收益。仿真结果表明, 在严格遵守设备运行约束的前提下, 所提出的方法不仅有效提升了系统整体经济性, 还兼顾了低碳环保的目标, 展现出良好的工程应用潜力。

关键词: 钢铁工业; 煤气-蒸汽-电力; 深度强化学习; 异构多智能体; 分时电价

Optimal Scheduling of Multi-Energy Coupled Systems in the Steel Industry Based on Heterogeneous Multi-Agent Deep Reinforcement Learning

HU Xiao¹, JIA Jinguo¹, XU Xiandong², YANG Jiaquan³, LIANG Junyu³, WANG Shili⁴

(1. Department of Electrical Engineering, Northeast Electric Power University, Jilin, Jinlin 132012, China; 2. School of Electrical and Information Engineering, Tianjin University, Tianjin 300072, China; 3. CSG Yunnan Electric Power Research Institute, Kunming 650217, China; 4. Yunnan Qujing Chenggang Steel (Group) Co., Ltd, Qujing, Yunnan 655100, China)

Abstract: Addressing the high complexity inherent in the synergistic optimization and scheduling of gas-steam-power coupled systems in the steel industry, this paper proposes an optimization decision-making framework based on Multi-Agent Deep Reinforcement Learning (MADRL). Focusing on the gas, steam, and power systems within the steel sector, the study models the multi-objective optimization task as a Markov Decision Process (MDP). A system model integrating dynamic equipment characteristics and Time-of-Use (TOU) electricity pricing mechanisms is constructed, aiming to achieve efficient allocation of gas and steam resources while enhancing the economic benefits of waste heat power generation. In terms of methodological design, a heterogeneous multi-agent architecture is proposed, which combines agents utilizing the Deep Deterministic Policy Gradient (DDPG) algorithm and those employing the Deep Q-Network (DQN) algorithm to handle continuous control problems (e.g., flow regulation) and discrete control problems (e.g., equipment switching) respectively. For the continuous-action agents, an Actor-Critic structure based on Long Short-Term Memory (LSTM) networks is introduced to better capture the system's dynamic changes and historical dependencies across multiple time scales. By collaboratively optimizing gas holder buffer regulation, steam network pressure balance, and waste heat generation scheduling, the model significantly improves the system's economic revenue under the TOU pricing mechanism. Simulation results demonstrate that, while strictly adhering to equipment operational constraints, the proposed method not only effec-

基金项目：国家重点研发计划资助 (2023YFB2407300)。

Foundation item: Supported by the National Key Research and Development Program of China (2023YFB2407300).

tively enhances the overall economic performance of the system but also considers low-carbon environmental goals, showing considerable potential for engineering applications.

Key words: steel industry, gas-steam-power, deep reinforcement learning, heterogeneous multi-agent, time-of-use electricity pricing

0 引言

钢铁工业作为全球能源消耗与碳排放的核心领域之一,其能源系统具有煤气、蒸汽与电力三种能源介质协同作用的多能流耦合特性^[1-3],呈现出复杂的供需平衡与多时间尺度交互特性。在“双碳”战略背景下^[4-5],如何通过多能协同优化实现能源的高效利用、提升余热发电收益,并增强与电网的调峰协同能力,已成为推动钢铁行业绿色低碳转型的关键课题。然而,当前钢铁企业普遍面临诸如煤气放散率高、余热发电效率低以及电网峰谷负荷矛盾突出等实际问题,亟需有效的系统性优化调度方法加以解决。

针对上述挑战,国内外学者围绕钢铁生产过程中能源介质的优化分配开展了大量研究,但大多聚焦于单一能源介质的调度与优化:文献[6]以降低系统运行总成本为目标函数建立副产煤气优化调度模型,实现富余煤气在缓冲用户间的优化分配和煤气的零放散。文献[7-8]通过对富余煤气在缓冲设备之间的优化分配问题,并通过计算得到最佳煤气柜容量和最佳锅炉负荷,减少煤气的放散,提高锅炉效率。文献[9]以高炉煤气为研究对象,建立高炉煤气系统的综合优化模型和流程网络模型,合理分配煤气介质的产生量和消耗量。然而,上述研究多局限于单一介质(煤气、蒸汽或电力)的孤立优化框架,未能充分考虑煤气、蒸汽与电力之间的动态耦合机制,导致跨介质能量传递损失与全局能效评估偏差,难以实现多能流协同下的整体最优。

为应对多介质耦合问题,已有部分研究尝试引入多能流协同调度的思路:文献[10]依据 HP 滤波和 Elman 神经网络性质建立了 HP(2)-Elman 预测模型,并根据自备电厂能源利用的特点,建立拟合模型求解锅炉的经济运行负荷,在此基础上对富余煤气进行优化调度。文献[11-12]考虑建立了煤气-蒸汽-电力等多介质多周期混合优化调度的数学模型,实现了多种能源介质的最优分配、转换和使用。文献[13]根据生产周期内煤气、蒸汽和电力的供应与需求分析,建立了多操作周期、多能源介质耦合优

化分配模型,对 3 种煤气、2 种蒸汽和电力进行优化分配。然而,这些方法大多采用离线优化或周期性静态调度模式,其决策过程缺乏与动态环境的实时交互反馈,难以有效应对煤气波动突发性、蒸汽管网压力瞬变等工业场景中的强不确定性,导致调度策略存在滞后性且鲁棒性不足

深度强化学习(DRL)能够通过智能体与环境的交互,在复杂不确定环境中自主学习最优策略,为时序决策问题提供了新途径^[14-16],多智能体深度强化学习(MADRL)进一步通过智能体间的协作,提升了解决复杂系统问题的能力,并在能源调度领域展现出潜力。然而,现有研究在将其应用于钢铁多能耦合系统时仍面临一下挑战:(1)钢铁调度中同时包含连续调节与离散决策的混合动作空间,现有方法多采用同构智能体或单一算法,难以兼顾二者,若将连续动作离散化则易引发维度灾难与精度损失;(2)多数研究未能充分考虑系统在多时间尺度下的动态惯性与历史依赖性,限制了策略的时序适应能力;(3)在奖励函数设计与训练机制上,对如何在强不确定性环境下平衡经济收益最大化与运行约束严格满足的多目标优化问题,仍需更精细的建模与泛化能力提升。

针对上述研究不足,本文提出一种面向钢铁工业多能耦合系统的异构多智能体深度强化学习^[17-18]优化调度方法。首先,提出 DDPG-DQN 异构多智能体协同优化框架。针对混合动作空间处理的难题,构建融合深度确定性策略梯度(DDPG)与深度 Q 网络(DQN)的异构智能体架构。其次,为提升策略对系统动态历史依赖的建模能力,在 DDPG 智能体的 Actor-Critic 网络中嵌入长短期记忆(LSTM)模块,最后,设计了融合即时发电收益与运行约束违反惩罚的双重奖励函数,并在状态空间中引入服从高斯分布的随机扰动,结合规范化的数据集划分,以提升模型在不确定工况下的泛化能力与鲁棒性。

1 钢铁工业多能耦合系统建模

1.1 多能耦合系统工艺流程

钢铁工业煤气-蒸汽-电力耦合系统是典型的多样化复杂工艺组合的工业负荷。其主要工艺流程为：煤气与蒸汽的产生环节、存储环节、消耗环节和发电环节，其工艺流程示意图如图 1 所示。




图 1 煤气-蒸汽-电力耦合系统工艺流程图

Fig. 1 Process flow diagram of the gas-steam-power coupled system

在钢铁工业的生产工艺流程中，煤气与余热蒸汽主要在高温冶炼过程中生成，经由输送管道输送至存储、消耗及发电等环节。煤气的具体分配则需根据各类用能设备的实际需求及发电计划进行动态调整，实现资源的合理消耗、发电与储存的协同管理。

1.2 系统运行分析

钢铁工业多能耦合系统的关键在于实现煤气与蒸汽两种能源流之间的动态平衡与协同调度。本文以某典型无焦化工序钢铁企业为研究对象，重点分析高炉煤气（Blast Furnace Gas, BFG）、转炉煤气（Linz - Donawitz Gas, LDG）、余热蒸汽和电能之间的能量交互关系。

在煤气产生环节，主要涉及的设备包括高炉、转炉，高炉和转炉分别产生 BFG 和 LDG；在余热蒸汽产生环节，主要设备包括转炉和加热炉。由于后续的能源消耗与发电环节均依赖于产气环节的供给能力，其运行过程必须严格遵循质量守恒定律，具体表现为：

$$G_{BFG,t}^{pro} = \sum_{i \in C_{BFG}} G_{BFG,i,t}^{con} + G_{BFG,t}^{ven} \quad (1)$$

$$G_{LDG,t}^{pro} = \sum_{j \in C_{LDG}} G_{LDG,j,t}^{con} + \Delta G_{LDG,t}^{sto} + G_{LDG,t}^{ven} \quad (2)$$

式中， $G_{BFG,t}^{pro}$ 、 $G_{LDG,t}^{pro}$ 分别表示高炉煤气和转炉煤气的产生量， $\sum_{i \in C_{BFG}} G_{BFG,i,t}^{con}$ 、 $\sum_{j \in C_{LDG}} G_{LDG,j,t}^{con}$ 分别表示消耗环节各设备消耗的高炉、转炉煤气量，设备包括高炉、烧结机、钢包和加热炉， $G_{BFG,t}^{ven}$ 表示发电机组消耗的高炉煤气量， $G_{LDG,t}^{ven}$ 表示发电机组消耗的转炉煤气量， $\Delta G_{LDG,t}^{sto}$ 表示煤气柜内转炉煤气增量。

对于余热蒸汽需进一步建立蒸汽子系统动态模型。钢铁生产过程中，余热蒸汽作为二次能源的核心载体，其流动平衡直接影响系统能效。蒸汽主要来源于高温工艺余热回收，关键产汽单元包括炼钢转炉与轧钢加热炉；消纳路径集中于余热发电机组及管网存储系统。据此定义以下守恒关系：

余热蒸汽总产生量由主产汽设备贡献，满足：

$$G_{whs,tot,t}^{pro} = G_{whs,cov,t}^{pro} + G_{whs,hea,t}^{pro} \quad (3)$$

式中， $G_{whs,cov,t}^{pro}$ 为转炉产生的余热蒸汽量，

$G_{whs,hea,t}^{pro}$ 为加热炉产生的余热蒸汽量。

余热蒸汽总消耗量涵盖发电消耗与管存变化量：

$$G_{whs,tot,t}^{con} = G_{whs,t}^{ven} + \Delta G_{whs,sto,t}^{con} \quad (4)$$

式中， $\Delta G_{whs,sto,t}^{con}$ 为管道存储的余热蒸汽增量（输入为正，输出为负）， $G_{whs,t}^{ven}$ 为余热发电机组消耗的余热蒸汽量。

在明确煤气与蒸汽子系统的动态平衡模型后，进一步将电力系统纳入整体耦合框架。

电力系统的核心耦合关系体现为能量守恒：系统总发电量由煤气发电机组与余热发电机组共同贡献；系统总耗电量则主要来源于高炉、转炉、烧结机和电热炉等核心工艺设备的电力消耗。据此，定义电力平衡方程为：

$$P_{tot,t}^{pro} = P_{G,t}^{pro} + P_{whs,t}^{pro} \quad (5)$$

$$P_{tot,t}^{con} = P_{BF,t}^{con} + P_{LD,t}^{con} + P_{sin,t}^{con} + P_{LF,t}^{con} \quad (6)$$

式中， $P_{tot,t}^{pro}$ 为总发电功率， $P_{G,t}^{pro}$ 和 $P_{whs,t}^{pro}$ 分别为煤气发电机组与余热发电机组的发电功率； $P_{tot,t}^{con}$ 为总用电功率， $P_{BF,t}^{con}$ 、 $P_{LD,t}^{con}$ 、 $P_{sin,t}^{con}$ 、 $P_{LF,t}^{con}$ 分别表示高炉、转炉、烧结机、电热炉的用电功率。

基于此, 电网购电量由下式决定:

$$\Delta P_{\text{grid},t}^{\text{red}} = P_{\text{tot},t}^{\text{pro}} - P_{\text{tot},t}^{\text{con}} \quad (7)$$

其中, $\Delta P_{\text{grid},t}^{\text{red}}$ 表示电网购电量, $\Delta P_{\text{grid},t}^{\text{red}} < 0$ 表示需从电网额外购电, $\Delta P_{\text{grid},t}^{\text{red}} > 0$ 表示可向电网额外售电 (减少从电网购电)。

该电能平衡关系与前述煤气、蒸汽动态方程共同构成了煤气-蒸汽-电力多能流耦合系统的核心物理约束, 为后续协同优化调度模型奠定了系统层面的运行基础。

1.3 设备特性分析

在钢铁工业煤气-蒸汽-电力耦合系统复杂流程的建模中, 针对设备的特性分析是构建高精度模型的基础环节, 对于设备的运行状态、气体流量、消耗边界及发电设备的功率进行具体分析。

在明确高炉煤气与转炉煤气的动态平衡约束后, 需进一步刻画关键用能设备的煤气消耗行为。根据烧结机的运行状态呈现离散特性 (停机/运行), 其高炉煤气消耗量可表示如下:

$$G_{\text{BFG},\text{sin}}^{\text{con}} = \begin{cases} 0, & \text{if } x=0 \\ \omega, & \text{if } x=1 \end{cases} \quad (8)$$

式中, $x=0$ 表示烧结机停止运行状态, 此时消耗的高炉煤气量为 0, $x=1$ 表示烧结机投入运行状态, 此时消耗的高炉煤气量为 ω 。

基于煤气动态平衡与设备工况模型, 关键用能单元的物理运行边界需纳入建模框架。加热炉作为高炉煤气的主要消耗设备之一, 其需求量受工艺热负荷与设备设计参数限制, 需满足以下区间约束:

$$G_{\text{BFG},\text{hea},t}^{\text{min}} \leq G_{\text{BFG},\text{hea},t}^{\text{cons}} \leq G_{\text{BFG},\text{hea},t}^{\text{max}} \quad (9)$$

式中, $G_{\text{BFG},\text{hea},t}^{\text{min}}$ 和 $G_{\text{BFG},\text{hea},t}^{\text{max}}$ 分别为加热炉维持最低热效率与安全运行的高炉煤气消耗量下限和上限。该约束直接关联工艺稳定性与能源利用效率。

在明确加热炉等高炉煤气消耗单元的刚性约束后, 需进一步构建转炉煤气储气柜的动态存储模型。煤气柜作为转炉煤气供需平衡的关键缓冲环节, 其存储量随输入输出流量动态变化, 满足以下连续性方程:

$$G_{\text{LDG},\text{in},t} - G_{\text{LDG},\text{out},t} = \Delta G_{\text{LDG},t}^{\text{sto}} \quad (10)$$

式中, $\Delta G_{\text{LDG},t}^{\text{sto}}$ 表征时段 t 内储气柜中转炉煤气的净增量, 其值由输入流量 $G_{\text{LDG},\text{in},t}$ 与输出流量 $G_{\text{LDG},\text{out},t}$ 的动态差值决定。

基于净增量 $\Delta G_{\text{LDG},t}^{\text{sto}}$, 储气柜总存量随调度周期累积更新:

$$S_{\text{LDG},t} = S_{\text{LDG},t-1} + \Delta G_{\text{LDG},t}^{\text{sto}} \quad (11)$$

式中, $S_{\text{LDG},t}$ 和 $S_{\text{LDG},t-1}$ 分别为 t 时刻和 $t-1$ 时刻煤气柜内的转炉煤气量。

考虑其进出口流量的物理运行边界。受储气柜压缩机功率、管道输送能力及安全运行限制, 对煤气的输入流量与输出流量设立上下限限制, 转炉煤气的输入与输出流量需满足以下不等式约束:

$$G_{\text{LDG},\text{in},t}^{\text{min}} \leq G_{\text{LDG},\text{in},t} \leq G_{\text{LDG},\text{in},t}^{\text{max}} \quad (12)$$

$$G_{\text{LDG},\text{out},t}^{\text{min}} \leq G_{\text{LDG},\text{out},t} \leq G_{\text{LDG},\text{ou},t}^{\text{max}} \quad (13)$$

式中, $G_{\text{LDG},\text{in},t}^{\text{min}}$ 与 $G_{\text{LDG},\text{in},t}^{\text{max}}$ 分别为时段 t 内煤气柜允许的最小与最大输入流量, 单位为 m^3/h , 由压缩机设计参数及管网压力阈值确定。 $G_{\text{LDG},\text{out},t}^{\text{min}}$ 常对应维持下游用户最低需求的流量 $G_{\text{LDG},\text{ou},t}^{\text{max}}$ 为管道最大输送能力。

考虑煤气柜的转炉煤气存量需始终处于设计安全范围内, 避免超压或负压风险:

$$S_{\text{LDG},t}^{\text{min}} \leq S_{\text{LDG},t} \leq S_{\text{LDG},t}^{\text{max}} \quad (14)$$

式中, $S_{\text{LDG},t}^{\text{min}}$ 为煤气柜允许的最小安全储量, 用于维持管网压力稳定; $S_{\text{LDG},t}^{\text{max}}$ 为煤气柜最大设计容量, 由气柜几何结构与材料强度决定。

对余热蒸汽管存系统施加类似的物理边界限制。与煤气柜类似, 蒸汽管存作为重要的缓冲单元, 其存储量同样需维持在安全运行范围内, 以避免系统超压或蒸汽品质下降。因此, 余热蒸汽管存需满足以下容量约束:

$$S_{\text{whs},t}^{\text{min}} \leq S_{\text{whs},t} \leq S_{\text{whs},t}^{\text{max}} \quad (15)$$

式中, $S_{\text{whs},t}^{\text{min}}$ 为管道系统允许的最小蒸汽储量, 用于维持管网压力稳定; $S_{\text{whs},t}^{\text{max}}$ 为管道系统最大设计容量, 由管道尺寸和承压能力决定。

进一步明确煤气发电机组与余热发电机组的运行特性及其在耦合系统中的约束关系。煤气发电机组的发电功率由消耗的高炉煤气量和转炉煤气量共同决定, 满足热电转换关系:

$$W_{G,t}^{\text{pro}} = k_1 \times G_{\text{BFG},t}^{\text{ven}} + k_2 \times G_{\text{LDG},t}^{\text{ven}} \quad (16)$$

式中, k_1 和 k_2 分别为高炉煤气与转炉煤气的发电转换系数, $W_{G,t}^{\text{pro}}$ 表示单位体积煤气所能产生的电能。类似地, 余热发电机组的发电功率由消耗

的余热蒸汽量决定：

$$W_{whs,t}^{pro} = k_3 \times G_{whs,t}^{ven} \quad (17)$$

其中， k_3 为余热蒸汽的发电转换系数， $W_{whs,t}^{pro}$ 表示单位质量余热蒸汽所能产生的电能。

受限于设备设计参数、热力循环效率及安全运行要求，两类发电机组的发电功率均需满足相应的运行区间约束：

$$P_{G,t}^{pro,min} \leq P_{G,t}^{pro} \leq P_{G,t}^{pro,max} \quad (18)$$

$$P_{whs,t}^{pro,min} \leq P_{whs,t}^{pro} \leq P_{whs,t}^{pro,max} \quad (19)$$

式中， $P_{G,t}^{pro}$ 表示煤气发电机组的发电功率， $P_{G,t}^{pro,min}$ 和 $P_{G,t}^{pro,max}$ 分别为煤气发电机组允许的最小与最大发电功率； $P_{whs,t}^{pro}$ 表示余热发电机组的发电功率， $P_{whs,t}^{pro,min}$ 和 $P_{whs,t}^{pro,max}$ 分别为余热发电机组允许的最小与最大发电功率。

2 多能耦合系统调度决策 MDP 框架

本文利用深度强化学习对钢铁工业煤气-蒸汽-电力耦合系统的调度决策问题进行求解，用以处理具有混合动作类型的复杂多能流耦合系统。首先，将调度决策问题的数学表述转化为强化学习的 MDP 框架，MDP 是强化学习的数学基础框架，由包含 S 、 A 、 P 、 R 、 γ 五个数组的五元组定义，其中 S 表征环境所有可能的状态集合， A 表征智能体可执行的动作集合， P 表征状态 s 执行动作 a 后转移到状态 s 的概率， R 表征执行动作后所获得的即时奖励， γ 表征当前奖励与未来奖励之间的重要性程度。

在本文中，煤气-蒸汽-电力耦合系统的调度决策问题被建模为一个基于 DRL 的智能体学习过程。智能体通过在系统运行过程中不断对各类设备进行状态感知与调度决策，经过多轮次的训练与策略更新，逐步学习并收敛到理想的最优调度策略。在每一调度时段 t 环境会给智能体反馈观测到的环境中各设备的运行状态 s_t ，智能体基于策略和系统运行状态 s_t 生成动作 a_t ，并获取所得奖励 r ，智能体会将 at 再次传递给环境进行自我更新，完成一个完整的交互周期，并开启新一轮的学习迭代。

系统的观测状态向量主要包括以下信息： t 时刻的各设备的产气量、耗气量和存储设备当前时刻的状态，各发电机组的发电功率以及电网分时电价，

对于煤气-蒸汽-电力耦合系统调度决策，其状态可以表示为

$$S = [G_{BFG,t}^{pro}, G_{LDG,t}^{pro}, G_{BFG,t}^{con}, G_{LDG,t}^{con}, G_{whs,t}^{pro}, G_{whs,hea,t}^{pro}, S_{LDG,t}, S_{whs,t}, P_{tot,t}^{con}, Price(t)] \quad (20)$$

状态空间用于定义智能体在调度过程中所能感知的所有可能环境状态的集合，是智能体与外部环境交互的核心依据。本部分构建了一个融合多源异构信息的状态空间。该状态空间不仅包含表征系统瞬时平衡的各类产气量、耗气量与设备实时状态，还引入了存储设备（如煤气柜、蒸汽管存）的存量信息，以捕捉系统的物理惯性与缓冲能力；同时，将分时电价作为外部经济激励信号纳入状态观测，使智能体能够感知并响应电价波动。

动作空间则描述了智能体在每一时刻可执行的控制行为集合，是调度策略输出的直接结果。在煤气系统调度中，需明确可控的关键操作变量，并将其整合为统一的动作向量。本文构建两个动作空间，分别为连续和离散动作空间，涵盖了以下关键控制动作：

$$A_1 = [G_{BFG,sin,t}^{con}, G_{BFG,hea,t}^{con}] \quad (21)$$

$$A_2 = [G_{LF,t}^{con}, G_{BFG,gen,t}^{con}, G_{LDG,gen,t}^{con}, G_{whs,gen,t}^{con}] \quad (22)$$

其中， A_1 为离散动作空间， A_2 为连续动作空间。

构建的混合动作空间通过将混合动作空间依其物理本质进行分解，映射至异构多智能体架构中的分工机制，在系统状态空间与奖励函数的引导下，生成符合设备物理约束、响应分时电价的调度策略。

在马尔可夫决策过程中，给定时间步 t 的状态 s_t 和动作 a_t ，系统转移至下一状态 s_{t+1} 的条件概率定义为状态转移概率：

$$p(s'|s,a) = \Pr(S_{t+1} = s' | S_t = s, A_t = a) \quad (23)$$

$p(s'|s,a)$ 蕴含了煤气柜存储波动、蒸汽管道压力变化、发电设备响应迟滞等过程，示钢铁工业煤气-蒸汽-电力耦合系统的状态转移概率分布，量化了在状态 s 下执行动作 a 后转移到后继状态 s' 的可能性。本质上刻画了煤气、蒸汽、电力在复杂工况下的耦合机制。

智能体在时间步 t 执行动作 a_t 后获得的即时奖励 rt 由环境反馈机制生成，作为策略网络优化的核心导向信号。在钢铁工业的煤气-蒸汽-电力耦合系统优化调度问题中，奖励函数的设计需兼顾经济效益与运行约束，以引导智能体在学习过程中动态

响应分时电价波动、提升高峰时段的发电收益,同时有效抑制煤气放散与关键设备越限等运行风险。

为实现上述目标,本文构建了一种双组分结构的奖励函数,由经济收益项与约束惩罚项共同组成,并通过缩放因子对两者的权重进行调控,从而在保障系统运行安全性的同时,引导策略实现全周期内的发电价值最大化。该奖励函数可形式化表示为:

$$R(s_t, a_t) = \sigma_1 R_1(s_t, a_t) + \sigma_2 P_c(s_t, a_t) \quad (24)$$

式中: σ_1 为获取的发电收益的缩放系数, σ_2 为约束惩罚的等值缩放系数, $R_1(s_t, a_t)$ 为当前时段获取的发电收益, $P_c(s_t, a_t)$ 为当前时段所受到的约束惩罚。

在煤气-蒸汽-电力耦合系统的状态 s_t 确定时,动作 a_t 的综合效用可通过嵌入惩罚因子的状态-动作价值函数 $Q_\pi(s, a)$ 评估,该函数显式量化调度决策的长期经济收益与约束违反风险,即

$$Q_\pi(s, a) = R(s, a) + \gamma \sum_{s' \in S} P(s' | s, a) \max_{a' \in A} Q^*(s', a') \quad (25)$$

式中 $\gamma \in [0, 1]$ 为折扣因子,反映了未来各时段奖励在累计奖励中所占比重的大小, γ 越大,则代表未来奖励所占的比重越大。

钢铁工业煤气-蒸汽-电力耦合系统调度决策的目标是找到最优策略,使奖励值最大化,从而寻找到最优方案,如式(26)所示:

$$\pi^*(s) = \arg \max_{a \in A} Q^*(s, a) \quad (26)$$

3 基于 DDPG-DQN 异构多智能体协同优化的问题求解

在钢铁工业多能耦合系统的优化调度问题中,控制变量涉及连续调节行为(如功率输出、流量调节)与离散决策行为(如设备启停),构成具有混合动作空间的调度控制场景。传统的单一类型强化学习算法在处理此类混合动作空间时存在显著局限性:基于值函数的方法(如 Deep Q-Network, DQN)擅长处理离散动作,但面对连续动作时往往需要将其离散化处理,若采用单一 DQN 算法,则需将连续动作离散化,这样容易引发动作维度激增与维数灾难,导致学习效率下降与策略精度受损;而基于策略梯度的方法(如 Deep Deterministic Policy Gradient, DDPG)虽然适用于连续动作空间,但对离散决策问题的处理能力较弱,难以兼顾离散逻辑与连续调节的协同优化,若采用单一 DDPG 算法,

则难以高效处理烧结机等设备的离散启停控制。

为此,本文提出一种基于 DDPG-DQN 异构多智能体协同优化的方法,用于求解具有混合动作空间的钢铁工业多能耦合系统调度问题。该方法将具备连续动作处理能力的 DDPG 智能体与擅长离散决策的 DQN 智能体进行功能分工与协同训练,分别负责系统中的不同控制变量,实现整体策略的高效优化与精细控制。该方法的本质是对调度中混合动作空间的结构化分解与协同求解,在每一决策时刻,DDPG 与 DQN 智能体共享同一全局环境观测状态,并依据各自处理的动作类型并行决策,DDPG 输出连续调节量, DQN 输出离散启停指令;输出的动作构成完整控制指令交由环境执行。环境反馈的单一即时奖励,融合了所有动作产生的经济收益与违反约束的惩罚,构成驱动两类智能体策略更新共同优化目标。通过这种机制,异构智能体在训练中自发学习相互配合,从而实现对复杂耦合系统的高效协同调度,算法伪代码如表 1 所示。

表 1 DDPG-DQN 协同优化方法伪代码

Tab. 1 Pseudocode of the DDPG-DQN synergistic optimization approach

钢铁工业多能耦合系统模型的 DDPG-DQN 异构多智能体协同优化方法求解	
1:	初始化 DDPG 智能体, 初始化 DQN 智能体, 获取初始状态
2:	添加高斯噪声增强泛化能力
3:	for 序列 $e = 1: E$ do
4:	for 时间步长 $t = 1: T$ do
5:	DDPG 智能体根据当前状态选择连续动作, DQN 智能体根据当前状态选择离散动作, 在环境中执行动作得到下一个、状态、奖励、终止信号
6:	将经验 (s_t, a_t, r_t, s_{t+1}) 、 $(s_t, a'_t, r_t, s_{t+1})$ 分别存储到经验池 D1、D2 中
7:	从经验回放中采样小批量, 通过最小化 TD 误差更新 Critic 网络, 使用 Critic 的梯度来最大化预期回报来更新 Actor 网络, 更新目标网络
8:	从经验回放中采样小批量, 通过最小化 TD 误差计算目标 Q 值, 更新 Q 网络
9:	状态更新
10:	if 环境终止 结束当前回合, 计算该回合内总奖励
11:	end if
12:	end for
13:	end for
14:	保存训练好的智能体

在智能体架构方面, 本文基于 Simulink 平台构建了环境交互仿真系统, 智能体通过与环境之间的状态-动作-奖励闭环反馈机制, 完成调度策略的学习与优化。针对系统中不同类型的控制变量, 采用异构多智能体架构, 将具备处理连续动作能力

的 DDPG 智能体与擅长处理离散动作的 DQN 智能体进行功能分工与协同训练, 以实现混合动作空间下的联合优化。

其中, DDPG 智能体负责连续动作的决策任务, 并引入 LSTM 构建 Actor - Critic 框架, 以增强模型对系统动态特性与历史依赖关系的感知能力。Actor 网络根据当前状态生成动作策略, Critic 网络则用于评估该策略下的状态值或动作值, 从而指导策略优化。

在网络结构设计方面, DDPG 智能体首先将状态空间与动作空间的特征向量按维度拼接, 作为神经网络的输入, 实现对状态 - 动作联合特征的深层建模。Critic 网络由两层 ReLU 激活函数和两层 LSTM 结构组成, LSTM 层的神经元数分别设为 300 与 150; Actor 网络结构与 Critic 网络类似, LSTM 层的神经元数量分别设为 40 与 80。为确保输出动作在物理控制范围内的可行性, Actor 网络在输出端引入一组缩放层, 将经过 Tanh 激活函数的结果线性映射至目标动作的实际取值区间。DDPG 智能体的学习率设置为 0.001, 梯度裁剪阈值设为 1, 以增强训练稳定性。

DQN 智能体处理系统的离散动作, 通过深度神经网络 (DNN) 来近似 Q 函数 $Q_{\pi}(s, a)$, 从而评估在给定状态 s 下每个离散动作 a 的价值。DNN 通过多层神经元的组合, 将输入数据映射到输出结果, 从而实现复杂的函数近似。

为了防止寻优时陷入局部最优解, 增强模型对噪声的鲁棒性, 更好的获得全局最优解, 在状态量中加入服从高斯分布的随机扰动, 具体为:

$$s' = s + \epsilon \quad (27)$$

其中, ϵ 是服从高斯分布的随机扰动, 其分布可以表示为:

$$\epsilon \sim N(0, \sigma^2) \quad (28)$$

式中, $N(0, \sigma^2)$ 表示均值为 0, 方差为 σ^2 的高斯分布。

为评估异构多智能体模型的泛化能力与防止过拟合, 需构建规范化的数据集划分。

$$\begin{cases} R_{\text{train}} + R_{\text{val}} + R_{\text{test}} = 1 \\ R_{\text{train}} = 0.7 \quad R_{\text{val}} = 0.2 \quad R_{\text{test}} = 0.1 \end{cases} \quad (29)$$

式中 R_{train} 、 R_{val} 、 R_{test} 分别训练集、验证集、测试集比例。

4 算例仿真

4.1 仿真环境配置

钢铁工业为验证所提出调度决策方法的有效性, 本文以云南省某典型高耗能钢铁企业为研究背景, 基于 MATLAB/Simulink 平台构建了完整的煤气 - 蒸汽 - 电力耦合系统仿真模型。该模型涵盖了煤气存储装置、消耗设备、余热蒸汽装置以及多类型发电机组, 全面模拟了钢铁工业能源系统的运行特性与耦合关系。系统中的可控调度环节主要包括存储环节、消耗环节和发电环节, 其中后两者是实现能源优化与收益提升的核心控制单元。

基于上述工艺逻辑, 本文构建了一个可交互的多智能体仿真环境, 并分别部署 DDPG 与 DQN 两类智能体, 按动作类型对系统中的设备进行分组建模与决策控制。对于具备连续调节能力的设备, 如加热炉、钢包等, 其调节范围较广、运行状态连续变化, 适合采用 DDPG 智能体进行控制。DDPG 能够在精细粒度下调整输出功率或耗气量, 满足实时响应与动态优化的需求。

而对于如烧结机等具有离散运行状态的设备, 其工况一般划分为“启动”与“停止”两种状态, 动作空间呈典型离散特征。DDPG 在处理这类离散控制问题时精度不足, 离散动作建模不够直接。因此, 本文采用更适用于离散动作建模的 DQN 智能体来进行调度控制, 提升了策略执行的准确性与系统响应效率。系统调度时间长度为 24h, 时间间隔为 1h, 电价采用分时电价, 其中低谷时段为 23:00—7:00, 平时段为 7:00—9:00、12:00—17:00, 高峰时段为 9:00—10:00、11:00—12:00、18:00—23:00、尖峰时段为 10:00—11:00 和 17:00—18:00。转炉煤气柜设计容量为 98 000 m³, 安全运行要求储量下限为 9 800 m³, 上限为 98 000 m³。余热蒸汽管存系统设计容量为 75 kg, 运行中储量需控制在 67.5 kg 至 75 kg 之间。发电机组方面, 煤气发电机组的额定功率为 65 MW, 最小出力设定为 20 MW; 余热发电机组额定功率为 9 MW, 最小技术出力为 2.7 MW, 上限为 9 MW。上述参数构成了本文仿真模型中设备运行约束的具体量化边界。

智能体配置参数: 采样时间设置为 1, 目标网络采用软更新, 平滑系数采用 1×10^{-3} , 经验池长

度设置为 1×10^6 ，每次训练从经验池中抽取的样本数为 64，折扣因子设置为 0.9，训练时输入网络的序列长度应为大于 1 的值，以获取时间依赖关系，这里设置为 9。

训练设置：设置最大训练回合数为 5000，每回合的最大步数为 24，每步对应 1h 设置停止训练标准，当奖励值达到期望值时，停止训练。

4.2 算法性能对比分析

对数据进行预处理，采用处理后的数据对程序进行训练，为了验证所提方法的有效性，选择 DDPG 和 MAPPO 两种典型强化学习方法进行对比分析，如图 2 所示。




图 2 奖励曲线对比图

Fig. 2 Comparison of reward curves

在收敛性能上，所提 DDPG-DQN 异构多智能体在方法约 250 回合后奖励值即突破 450，显著早于 DDPG 和 PPO；在稳定性方面，在 1000 回合后稳定维持在 470 以上的高奖励平台期，波动幅度明显小于另外两种典型强化学习算法；从性能上来看，最终奖励值达到 480 以上，较 DDPG 和 MAPPO 分别提升 22.5% 和 8.3%。DDPG-DQN 在训练中期呈现近似平稳的趋势，表明异构智能体架构有效协调了 DQN 的离散决策能力与 DDPG 的连续控制优势。相较而言，标准 DDPG 算法在训练初期上升幅度与本文所提方法存在明显差距，并且后期奖励增长趋于平缓，未能充分利用系统的时序耦合特性。MAPPO 作为同构多智能体算法，虽在训练前期奖励值明显高于本方法，然而在中后期奖励值明显下降，表明其短暂陷入了局部最优解，在训练中后期虽然展现出了一定的协作学习能力，但其奖励曲线波动相对明显，并且性能低于本文所提方法。


基于 DDPG-DQN 异构多智能体的方法在训练过程中表现出更快的收敛速度和更优的收敛效果，且最终获得的累计奖励显著高于其他对比方

法。这一优势归因于钢铁工业煤气-蒸汽-电力耦合系统本身具有较高的状态-动作维度，若采用单一智能体进行全局建模，将面临计算负担重、学习效率低等问题。而异构多智能体方法通过 DDPG 与 DQN 两类智能体协同处理连续与离散动作任务，有效分解了控制维度，降低了单个智能体的计算复杂度，提升了整体的求解效率与系统适应性。


4.3 协同调度效果分析

依据对奖励曲线的分析证明了本方法具有一定的优越性，分别对各存储设备储量、各发电机组发电量和各煤气放散量进行分析，进一步验证所提方法的有效性。

煤气柜和蒸汽管道作为存储设备，在实际运行中对于煤气-蒸汽-电力系统优化调度具有重要作用，特点是在电价低的时段，增加气体的输入量，减小输出量，增加煤气和蒸汽的存储量，在电价较高的时段，减少输入量，增加输出量，将存储的煤气尽可能多的释放，大量供给给发电机组发电和平衡耗气设备的需求，如图 3 所示。



(a) 煤气柜内转炉煤气储量变化



(b) 管道内蒸汽存储量变化

图 3 副产气体储量波动示意图

Fig. 3 Schematic diagram of byproduct gas storage level fluctuations

在异构多智能体系统的协同调度下，转炉煤气柜与余热蒸汽管存呈现一定的时序互补特性，5:00-9:00 包含低谷时段和平时段，此时低价从外部购电，对转炉煤气和余热蒸汽进行大量存储，提升煤气回收强度，利用低价电能驱动蒸汽压缩机，将余热蒸汽管存压力提升至峰值，降低压缩工序的边

际成本。9:00-12:00 为高峰时段和尖峰时段,此时将存储的转炉煤气和余热蒸汽进行大量释放,减少从外部电网购电,13:00-17:00 为低谷时段,此时总体上仍然对储量进行大幅提升,在 17:00-19:00 时段储量释放发电,其他时段保持正常运行。

在异构多智能体系统的协同调度下,高炉煤气、转炉煤气与余热蒸汽三种副产能源的发电行为呈现显著的分时电价响应特征。高炉煤气工艺流程中不包含储气设备,只能间接通过转炉煤气柜来调节,因此在全天保持相对平稳,尽管发电量都保持在 40MWh 左右,然而尖峰时段的收益相比于低谷时段却达到接近 2 倍,充分验证智能体“稳发电、高套利”的调度策略,具体如图 4 所示。




图 4 各副产气体发电量与收益之间的关系

Fig. 4 Relationship between power generation and revenue for each byproduct gas

针对于转炉煤气发电,在图 4(b)中,智能体锁定电价高峰触发发电:早高峰(9:00-10:00)每时段发电量都在 15.8MWh 左右,收益大概为 105000 元;晚高峰(18:00-20:00)发电量最高 16.5MWh,收益 110550 元。

余热蒸汽大部分仅供给余热发电机组发电,且不会产生碳排放,因此严格根据分时电价以获取发电收益最大化,并且根据蒸汽发电的稳定特性平抑煤气系统的收益波动,可以看出在电价尖峰时段普

遍更高,发电量最高可达 7.175 MWh,可以看出并不能完全调控蒸汽发电量全部处于尖峰时段,这是由于其热惯性及管存容量的限制。针对副产煤气放散量的减少,在强化学习模型中设立了相应的煤气放散惩罚系数,经过智能体针对收益和放散惩罚两者进行权衡之后,得到如图 5、图 6 的效果,从图中可以明显看出,高炉煤气的放散量有明显的降低,对于转炉煤气放散的减少同样显著,在 7:00-8:00 这个时间段,由于处于负荷峰值,煤气利用率高,甚至达到了零放散的效果。




图 5 高炉煤气方法前后放散量对比图

Fig. 5 Comparison of blast furnace gas discharge levels before and after method application.




图 6 转炉煤气方法前后放散量对比图

Fig. 6 Comparison of blast furnace gas discharge levels before and after method application.

4.4 鲁棒性测试分析

为进一步验证所提异构多智能体深度强化学习调度模型在复杂工业环境中的鲁棒性与适应性,本节针对煤气产量骤降这一典型极端工况进行仿真测试,旨在评估模型在突发强扰动下维持系统安全稳定运行、并严格遵守环保约束的能力。

钢铁生产中,高炉或转炉检修期间煤气产量会出现阶段性下降。为模拟此类情景,设定在仿真日的 9:00 - 10:00 时段,转炉煤气产量相较于正常工况情况下骤降 40%,高炉煤气产量同步下降 20%。该时段覆盖电价尖峰与高峰区间,并且为保障高炉、加热炉等工艺设备的用气需求,可用于发电的

煤气余量大幅减少,对于提高经济收益具有较大的影响。

模型通过对煤气柜缓冲与发电计划进行了协同调整,在减产前提前提升煤气柜的转炉煤气储量;在缺气时段降低煤气发电出力,保障煤气供给给耗气设备的同时,依托余热发电填补功率缺口;并且此时段煤气放散量控制效果显著,煤气放散接近 0,如图 7 所示。




图 7 鲁棒性测试结果图

Fig. 7 Results of the Robustness Test

由图中可以直观看出所提方法在煤气产量骤降时段的完整响应过程。在产量骤降发生前,转炉煤气柜储量与余热蒸汽管存均被主动提升至接近峰值

的水平,表明智能体已提前进行预防性储调,为即将到来的供给缺口做好准备。

当产量在 9:00 - 10:00 期间骤降时,系统立即转向“保供降耗”模式。图 7(a) 显示转炉煤气柜储量自 9:00 起由升转降,说明储存的煤气开始被释放,以补充当期产量缺口,优先确保工艺设备的用气需求;图 7(b) 中余热蒸汽储量也呈现类似调用趋势,协同支持发电环节。在整个调度过程中,两类储量的变化曲线均保持在安全上下限之间,无越限风险。

从放散控制效果看,在 9:00 - 10:00 这一关键扰动时段及后续期间,高炉煤气放散量(图 7c)仅出现小幅、瞬时波动,而转炉煤气放散量(图 7d)则被稳定压制在极低水平,尤其在 9:00 - 11:00 期间接近零放散。这清楚表明,即便在煤气供给突降的情况下,模型仍能有效协调资源分配,在保障系统基本运行的同时,严格抑制了煤气放散。

5 结论

本文针对钢铁工业中的多能耦合系统,提出了一种基于异构多智能体深度强化学习的优化调度方法。该方法提出了 DDPG-DQN 异构多智能体协同优化框架,能有效处理混合动作空间,并引入 LSTM 增强的 Actor-Critic 结构,提升了对系统动态与历史依赖的建模能力。最后,设计了融合即时发电收益与运行约束违反惩罚的双重奖励函数,并在状态空间中引入服从高斯分布的随机扰动;此外,通过划分训练集、验证集和测试集,提高了模型在实际应用中的寻优效果。

实验结果表明,该方法在提升系统经济性与环保性能方面具有显著优势。具体表现为:尖峰电价时段的发电收益占比进一步提高,系统全周期总收益增长 15.2%;高炉煤气放散量减少 32.9%,转炉煤气放散量减少 41.2%;年碳排放量减少达 120,741.2 吨。这些结果充分验证了所提方法在提升钢铁工业多能耦合系统经济效益与碳减排方面的有效性和实用价值。

参考文献

- [1] 初壮, 孙绍文, 周池. 基于多能流计算的电-气-热耦合综合能源系统静态电压气压安全分析[J]. 东北电力大学学报, 2025, 45(2): 82-92.
- CHU Z, SUN S W, ZHOU C. Static voltage and pressure security

- analysis of integrated electricity-gas-heat energy systems based on multi-energy flow calculation[J]. Journal of Northeast Electric Power University, 2025, 45(2): 82-92.
- [2] YUAN L, XIU Y, ZI L, ZHOU M X, QIU H N, LI L H. Study on coupling operation of multi-energy flow for integrated community energy system considering seasonal load characteristics[C] // 2017 IEEE Conference on Energy Internet and Energy System Integration (EI2). Beijing, China: IEEE, 2017: 1-6.
- [3] 李壹民, 邵振国, 黄圆皓, 等. 电-热综合能源系统仿射型区间多能流算法[J]. 中国电机工程学报, 2023, 43(9): 3429-3444.
- LI Y M, SHAO Z G, HUANG Y H, et al. Affine arithmetic based interval multi-energy flow algorithm for integrated electricity and heat energy systems[J]. Proceedings of the CSEE, 2023, 43(9): 3429-3444.
- [4] 顾广安, 陈科军. 基于电碳模型的电力系统碳排放预测与优化调度[J]. 电气技术与经济, 2025(9): 250-252.
- GU G A, CHEN K J. Carbon emission prediction and optimal scheduling of power system based on electric-carbon model[J]. Electrical Equipment and Economy, 2025(9): 250-252.
- [5] YU W, LI H, ZHANG Q, et al. Development status and technical challenges of new low-carbon technologies for power systems under the dual-carbon goal[C] // 2024 7th International Conference on Energy, Electrical and Power Engineering (CEEPE). Yangzhou, China: IEEE, 2024: 1054-1057.
- [6] YANG J H, CAI J J, SUN W Q, et al. Optimization and scheduling of byproduct gas system in steel plant[J]. J. Iron Steel Res. Int., 2015, 22(5): 408-414.
- [7] SUN W Q, CAI J J, SONG J. Plant-wide supply-demand forecast and optimization of byproduct gas system in steel plant[J]. J. Iron Steel Res. Int., 2013, 20(9): 1-8.
- [8] YANG J H, CAI J J, SUN W Q, et al. Optimal allocation of surplus gas and suitable capacity for buffer users in steel plant[J]. Appl. Therm. Eng., 2017, 115: 586-594.
- [9] 曹建全, 袁贞, 郝飞, 等. 基于流程网络的高炉煤气系统分析[J]. 自动化与信息工程, 2013, 34(2): 14-18.
- CAO J Q, YUAN Z, HAO F, et al. Analysis of blast furnace gas system based on process network[J]. Automation & Information Engineering, 2013, 34(2): 14-18.
- [10] 李红娟, 王建军, 王华, 等. 基于 HP(2)-Elman 模型的钢铁企业富余煤气预测及优化调度[J]. 钢铁研究学报, 2013, 25(7): 11-16.
- LI H J, WANG J J, WANG H, et al. Prediction and optimal scheduling of surplus gas in steel enterprises based on HP(2)-Elman model[J]. Journal of Iron and Steel Research, 2013, 25(7): 11-16.
- [11] 曾玉娇, 孙彦广. 钢铁企业蒸汽-电力系统多时段优化调度[C] // 第25届中国过程控制会议论文集. 大连: 中国自动化学会过程控制专业委员会, 2014: 8.
- ZENG Y J, SUN Y G. Multi-period optimal scheduling of steam-power system in steel enterprises[C] // Proceedings of the 25th Chinese Conference on Process Control. Dalian: Process Control Committee of CAA, 2014: 8.
- [12] 曾亮, 梁小兵, 欧燕, 等. 钢铁企业煤气-蒸汽-电力等多介质多周期混合优化调度模型及算法[C] // 全国冶金能源环保生产技术会论文集. 武汉: 中国金属学会, 2014: 252-257.
- ZENG L, LIANG X B, OU Y, et al. A multi-medium multi-period hybrid optimization scheduling model and algorithm for gas-steam-power system in steel enterprise[C] // Proceedings of the National Conference on Energy and Environmental Protection Technology in Metallurgical Industry. Wuhan: The Chinese Society for Metals, 2014: 252-257.
- [13] 张琦, 提威, 杜涛, 等. 钢铁企业富余煤气-蒸汽-电力耦合模型及其应用[J]. 化工学报, 2011, 62(3): 753-760.
- ZHANG Q, TI W, DU T, et al. Coupling model of surplus gas-steam-power in steel enterprise and its application[J]. CIESC Journal, 2011, 62(3): 753-760.
- [14] 王仁浚, 高红均, 罗龙波, 等. 基于深度强化学习的新型配电系统优化运行研究综述[J]. 电力自动化设备, 2025, 45(9): 152-164.
- WANG R J, GAO H J, LUO L B, et al. Review on optimal operation of new distribution system based on deep reinforcement learning[J]. Electric Power Automation Equipment, 2025, 45(9): 152-164.
- [15] 谭靖, 杨利刚, 李潇睿, 等. 深度强化学习及其在工业场景的应用与展望[J]. 工程科学学报, 2025, 47(4): 768-779.
- TAN J, YANG L G, LI X R, et al. Deep reinforcement learning and its application and prospect in industrial scenarios[J]. Chinese Journal of Engineering, 2025, 47(4): 768-779.
- [16] 刘延飞, 李超, 王忠, 等. 多智能体深度强化学习及可扩展性研究进展[J]. 计算机工程与应用, 2025, 61(4): 1-24.
- LIU Y F, LI C, WANG Z, et al. Research progress on multi-agent deep reinforcement learning and its scalability[J]. Computer Engineering and Applications, 2025, 61(4): 1-24.
- [17] 熊春萍, 马倩. 基于强化学习的异构多智能体系统最优输出调节[J]. Control Theory & Applications/Kongzhi Lilun Yu Yinyong, 2025, 42(3).
- XIONG C P, MA Q. Optimal output regulation for heterogeneous multi-agent systems based on reinforcement learning[J]. Control Theory & Applications, 2025, 42(3).
- [18] 程薇燃, 李金娜. 基于 Q 学习的异构多智能体系统最优一致性[J]. 辽宁石油化工大学学报, 2022, 42(4): 59.
- CHENG W R, LI J N. Optimal consensus for heterogeneous multi-agent systems based on Q-learning[J]. Journal of Liaoning Petrochemical University, 2022, 42(4): 59.
- [19] ZHANG T, ZHOU F, ZHAO J, WANG W. Deep Reinforcement Learning for Secondary Energy Scheduling in Steel Industry[C] // 2020 2nd International Conference on Industrial Artificial Intelligence (IAI). Shenyang, China: IEEE, 2020: 1-5.
- [20] WANG Z, HAN Z, ZHAO J, WANG W. An Uncertainty Involved Two-Stage Energy Optimization Framework Based on Deep Reinforcement Learning for Steel Enterprise[J]. IEEE Trans. Ind. Electron., 2025, 72(9): 9454-9464.
- [21] 田兵, 喻磊, 雷金勇, 等. 工业型用户侧微电网储能运行方式与微电网的运营模式[J]. 南方电网技术, 2016, 10(8): 48-55.
- TIAN B, YU L, LEI J Y, et al. Energy storage operation mode and operation model of industrial user-side microgrid[J]. Southern Power System Technology, 2016, 10(8): 48-55.
- [22] LIU C, TANG L, ZHAO C. A Novel Dynamic Operation Optimization Method Based on Multiobjective Deep Reinforcement Learning for Steelmaking Process[J]. IEEE Trans. Neural Netw. Learn. Syst., 2024, 35(3): 3325-3339.
- [23] 柳丹, 任建宇, 席磊, 等. 基于高维协同软演员-评论家的多智能体自动发电控制[J]. 南方电网技术, 2025, 19(4): 93-106.
- LIU D, REN J Y, XI L, et al. Multi-agent automatic generation con-

- trol based on high-dimensional collaborative soft actor-critic[J]. Southern Power System Technology, 2025, 19(4): 93-106.
- [24] 孙毅, 刘迪, 李彬, 等. 深度强化学习在需求响应中的应用[J]. 电力系统自动化, 2019, 43(5): 183-191.
- SUN Y, LIU D, LI B, et al. Application of deep reinforcement learning in demand response[J]. Automation of Electric Power Systems, 2019, 43(5): 183-191.
- [25] 李媛, 迟昆, 王洲, 等. 基于强化学习的电-气-热多微网系统定价策略[J]. 南方电网技术, 2024, 18(1): 94-101.
- LI Y, CHI K, WANG Z, et al. Pricing strategy for electricity-gas-heat multi-microgrid system based on reinforcement learning[J]. Southern Power System Technology, 2024, 18(1): 94-101.
- [26] 张琦, 蔡九菊, 庞兴露, 等. 钢铁联合企业煤气系统优化分配模型[J]. 东北大学学报(自然科学版), 2011, 32(1): 98-103.
- ZHANG Q, CAI J J, PANG X L, et al. Optimal distribution model of gas system in iron and steel complex[J]. Journal of Northeastern University (Natural Science), 2011, 32(1): 98-103.
- [27] ZHANG Q, ZHAO F, WANG T, ZHAO J, WANG W. A dual-reward dual optimization model based on hybrid RL for dynamic optimization of steel energy systems[C] // 2025 IEEE 14th Data Driven Control and Learning Systems (DDCLS). Wuxi, China: IEEE, 2025: 363-368.
- [28] 彭寒梅, 赵长桥, 谭貌, 等. 基于多智能体深度强化学习的大容量电池储能电站功率分配策略[J/OL]. 南方电网技术, 1-12[2025-09-23]. <https://link.cnki.net/urlid/44.1643.tk.20250422.0650.008>.
- PENG H M, ZHAO C Q, TAN M, et al. Power allocation strategy for large-capacity battery energy storage power station based on multi-agent deep reinforcement learning[J/OL]. Southern Power System Technology: 1-12[2025-09-23]. <https://link.cnki.net/urlid/44.1643.tk.20250422.0650.008>.
- [29] 江昌旭, 刘晨曦, 林铮, 等. 基于深度强化学习的电力系统暂态稳定控制策略研究综述[J]. 高电压技术, 2023, 49(12): 5171-5186.
- JIANG C X, LIU C X, LIN Z, et al. Review on transient stability control strategy of power system based on deep reinforcement learning[J]. High Voltage Engineering, 2023, 49(12): 5171-5186.

收稿日期: 2025-11-30

作者简介:

胡泉 (1989), 男, 通信作者, 讲师, 博士, 研究方向为综合能源系统运行分析与调控决策, xhu@neepu.edu.cn;

贾金国 (2000), 男, 硕士, 研究方向为钢铁工业多能耦合系统优化调度, jia15145720298@qq.com;

徐宪东 (1987), 男, 副教授, 博士, 研究方向为综合能源系统仿真模拟与灵活调控, xux27@tju.edu.cn。